

03 第2部分 - RAG

2.7 query路由

代码块

```
1  你是一名银行智能客服系统的 Query 路由助手。
2
3  请根据用户提出的问题，在以下知识库中选择一个最合适的知识源进行检索，并简要说明你的选择理由。
4
5  【可选知识库分类】：
6  1. 账户类知识库：与用户账户状态、余额、交易、还款等数据相关，通常需要查询用户私有信息。
7  2. 产品类知识库：涉及银行产品介绍，如信用卡、贷款、理财等服务说明与营销内容。
8  3. 流程规则知识库：与业务办理流程相关，如挂失、换卡、开卡流程、办理方式、所需材料等。
9  4. 公告通知知识库：包括系统维护公告、节假日放款时间、利率调整、公示类信息。
10 5. FAQ知识库：通用性强的高频问题，如客服电话是多少、服务时间、网点地址等。
11 6. 公开搜索引擎：用于查询跨行信息、外部新闻、舆情、行业对比、未同步公告等企业知识库以外的内容。
12
13
14  【示例1】
15  用户问题：我想查查银行卡里还有多少钱。
16  应路由至：账户类知识库
17  理由：用户在查询自己的账户余额，需要访问账户数据。
18
19  【示例2】
20  用户问题：你们现在有没有适合年轻人的理财产品？
21  应路由至：产品类知识库
22  理由：用户在咨询产品推荐，属于银行理财产品信息。
23
24  【示例3】
25  用户问题：我的卡丢了，怎么挂失？
26  应路由至：流程规则知识库
27  理由：用户在咨询具体操作流程，属于挂失办理指南类问题。
28
29  【示例4】
30  用户问题：你们是不是上周维护系统了？那天转账特别慢。
31  应路由至：公告通知知识库
32  理由：用户在询问历史系统维护记录，属于公告通知信息。
33
34  【示例5】
35  用户问题：你们客服电话多少？
36  应路由至：FAQ知识库
```

37 理由：属于高频通用问题，无需进入复杂系统或账户查询。

38

39 【示例6】

40 用户问题：你们是不是又被央视点名批评了？

41 应路由至：公开搜索引擎

42 理由：该问题属于舆情或媒体报道，企业内部知识库很可能未覆盖，应转由外部搜索引擎检索新闻或行业信息。

43

44

45 【请判断】

46 用户问题：{{用户输入的问题}}

47 应路由至：（请填写知识库名称）

48 理由：（请简要说明判断理由）

49

2.8 检索

1、倒排索引

是将“词 → 文档”的关系预先建立好，是一种从“词 → 文档”的索引结构。系统在面对关键词搜索时，可以不读所有文档而是直接查词表，快速找到包含某个词的所有文档。是现代搜索引擎和关键词检索系统的核心结构。

代码块

```
1  关键词->出现该词的所有文档ID列表
```

把“关键词”作为主入口去查哪些文档包含它，从内容反推文档，所以叫“倒排”

【举例】

假设有3篇文档：

代码块

```
1  ID1: "我 喜欢 吃 苹果"
2  ID2: "我 不 喜欢 吃 梨"
3  ID3: "苹果 和 梨 都 是 水果"
```

倒排索引是：

代码块

```
1  "我"      → [ID1, ID2]
2  "喜欢"    → [ID1, ID2]
3  "吃"      → [ID1, ID2]
4  "苹果"    → [ID1, ID3]
5  "梨"      → [ID2, ID3]
6  "水果"    → [ID3]
```

RAG中，如果涉及“关键词检索”（如使用 Elasticsearch / BM25）：系统就会先用倒排索引查“问题中每个关键词”有哪些文档匹配；再做打分排序，比如 BM25 相关性评分；最后返回Top-k文档送给大模型生成答案。

2、结构化数据检索

代码块

```
1  你是一个银行智能助手系统，当前需要根据用户提出的问题，从结构化关系型数据库中提取信息。
2
3  你的任务是将自然语言的问题，转化为标准 SQL 查询语句，以便查询数据库中的表格数据。
4
5  【数据库结构如下】（请据此生成SQL）：
6
7  表名：transactions
8  字段：
9  - id: 流水号
10 - user_id: 用户编号
11 - card_type: 卡片类型（如“招商银行信用卡”、“储蓄卡”）
12 - amount: 交易金额（单位：元）
13 - merchant: 商户名称
14 - date: 交易日期（格式：YYYY-MM-DD）
15 - status: 交易状态（success/failed）
16
17
18 请参考以下示例：
19
20 示例1：
21 用户问题：
22 “我3月份用招商银行信用卡消费最多的是哪一笔？”
23
24 推理链：
25 - 查询表 transactions
26 - 过滤条件：card_type = '招商银行信用卡' 且 date 属于 3月份
```

```
27 - 排序：按 amount 从大到小排序
28 - 限制：只取最大一条记录
29
30 SQL查询语句：
31 ```sql
32 SELECT merchant, amount, date
33 FROM transactions
34 WHERE card_type = '招商银行信用卡'
35     AND date >= '2024-03-01' AND date < '2024-04-01'
36 ORDER BY amount DESC
37 LIMIT 1;
38
39 现在请根据以下用户问题，生成标准SQL语句：
40 【用户问题】：
41 {user_question}
42
43 请输出格式：
44 SQL查询语句：
45 <你的SQL语句>
46
```

2.9 Reranker

关键词检索匹配词，向量理解意图，**重排序决定“看谁更相关”。三者合力是高质量 RAG 系统的基础。**

1、举例

用户问：“信用卡最低还款怎么算？是不是每次都能只还一点？”

(1) 关键词检索召回（查找出关键词“最低还款”、“信用卡”）

代码块

```
1 在知识库中检索出 Top-3 片段：
2
3 片段1：信用卡的最低还款额通常为账单金额的10%，部分银行为5%。最低还款会产生利息。
4 片段2：信用卡如果只还最低还款，剩余金额将从交易日开始按日计息，年化利率为18%左右。
5 片段3：信用卡挂失后，应尽快致电客服中心申请补卡。
6
```

(2) 向量语义检索

代码块在知识库中检索 Top-3 片段：

2

3 片段4：最低还款适用于暂时无法全额还款的客户，但会收取利息且影响免息待遇。

4 片段5：还款额不足最低还款会影响征信，建议按时足额还款。

5 片段1：信用卡的最低还款额通常为账单金额的10%，部分银行为5%。最低还款会产生利息。

(3) 重排序reranker

代码块

1 重排序得分（越高越相关）：

2

3 片段1：得分 0.91 最低还款额通常为账单的10%

4 片段2：得分 0.89 只还最低会产生利息

5 片段4：得分 0.86 最低还款不享受免息

6 片段5：得分 0.63 未按最低还款可能影响征信

7 片段3：得分 0.18（和挂失没啥关系） 与用户提问无关，排在最后

8

2.10 生成

代码块

1 你是一名银行智能客服系统的助手，请根据用户提出的问题与提供的知识文档，生成一段自然语言回答。

2

3 请严格遵循以下规则：

4 【任务目标】

5 - 回答必须准确、简洁，能直接满足用户提问

6 - 如果文档未包含答案，请明确表示无法确认，而不是自行编造

7

8 【语言风格】

9 - 使用礼貌、专业的客服语气

10 - 避免术语堆砌，要说“人话”，让用户容易理解

11

12 【格式要求】

13 - 1~2句话优先回答核心问题，必要时再附简要背景

14 - 如有多项内容，请使用项目符号（bullet list）或分段呈现

15 - 生成内容不得重复原文，应进行语言重组与提炼

16

17 【合规限制】

18 - 不得做出任何承诺性语言（如“保证收益”、“一定到账”）

19 - 涉及风险、理财、投诉等内容，需自动添加免责声明或引导用户联系人工

```
20
21    【输出结构】
22    请使用以下格式输出：
23    【回答】：（自然语言回答）
24    【提示】：（如需免责声明或建议转人工服务）
25
26    ---
27
28    【用户问题】：
29    {{用户的原始提问}}
30
31    【上下文文档片段】：
32    1. {{知识片段1}}
33    2. {{知识片段2}}
34    3. ...
35
36    【请生成】：
37
```

2.11 后处理

1、缓存

把曾经问过的问题和对应答案提前存下来，下一次再有人问同样或非常相似的问题时，直接返回缓存结果，跳过检索+生成过程，从而节省计算、提高响应速度。

（1）缓存会存什么？

一般缓存的 key 和 value 是这样的：

项目	示例
key	原始问题（或标准化后的问题，例如“查余额”）
value	LLM返回的最终回答（可能包括文档来源、参考 chunk、打分等）

（2）为什么用缓存？

“同样一个用户问题，RAG 系统每次都要查文档、构建上下文、让大模型生成一遍吗？”

举例：

- 1、用户问：我怎么退货？ 系统之前已经回答过了。
- 2 下一次别的用户再问，还得花0.01美元调用大模型？当然不！直接从缓存拿！
- 3
- 4 让 RAG更快、更便宜、更一致，在客服系统、电商搜索、政务问答中，它能让响应速度从5秒降到0.1秒。

(3) 缓存的时效性

给缓存设置“过期时间”，过了这个时间，缓存就不再使用，需要重新走一遍 RAG 流程。

比如：

- 用户问“2023年积分政策”，你缓存了一个答案；
- 2024年1月后，这个政策可能变了，那你就不该再用原来缓存的结果了 → 必须过期。

(4) 策略：

静态知识（如百科、产品介绍） → 可设长一点

动态知识（如优惠活动、库存） → 缩短为几小时或1天

可以去人工设置缓存时效的，按照你的场景来

意图类别	缓存时长建议（要按照你的实际情况来）
“积分如何使用”	30天
“促销活动规则”	7天
“公司历史介绍”	90天
“物流状态查询”	不缓存/5分钟

2、脱敏

后处理脱敏就是在大模型输出之后，识别并替换掉可能泄露的用户敏感字段，确保输出合规、安全。

类型	示例	脱敏方式（例）
用户姓名	张三	张*
身份证号	420101199001012233	420101*****2233
手机号	13888889999	138****9999
银行卡号	622700*****1234	尾号1234
交易单号	TX2024052500123	隐去中段表示
地址	北京市海淀区某某街道	隐藏详细门牌号

这个让技术去弄就好了，产品经理定好脱敏规则即可

3、RAG评估体系

3.1 白盒评估

白盒评估的本质是：将 RAG 拆解成多个可观测模块，每一环都设置指标，分别监测其质量和性能。

1、用户本身提问的问题

在很多 RAG 失败的结果中，不是模型问题，而是用户问题模糊、不规范、太短或缺失实体

代码块

- 1“我想看看那个东西发票的事儿”
- 2“怎么搞票据”

所以需要优化改写，或者是对用户的提问进行二次确认/追问

2、检索：

指标名称	含义说明	
意图识别准确率	用户Query是否正确路由到对应的知识库 / 检索路径	人工标注意图分类 或者 分类模型/LLM预测一致率
改写质量得分	改写后是否更容易召回目标文档？是否更标准规范？	对比改写前后 Recall@k、Precision@k
Recall@k（召回率）	Top-k 检索结果中是否包含真实答案的文档	需人工事先标注好“正确的参考答案”或“应当召回的文档片段”，再打分
Precision@k（准确率）	Top-k 中有多少是用户真正需要的内容（减少噪音）	你召回的前 k 条文档中，有多少是对的？——找回的这些里头，有没有太多废话、无关的段落？”

召回率 vs 准确率

假设：你想查 “与最低还款有关的文档片段”

代码块

1

假设知识库中有 **10条“正确的片段”** 应该被检索出来

2

你检索出了 **5条片段**，其中只有 **3条是正确的**，**2条是无关的**

3

4

准确率=3/5=0.6 检索到的5条中，60% 是有用的

5

召回率：3/10=0.3 应该找 10 条，只找到了 3 条

指标	衡量什么？	类比记忆
Precision@k	你找回来的里头有几个是对的？（纯度高不高）	你抓了5个人，有几个真的是小偷？
Recall@k	你该找的有没有找回来？（命中没）	你丢了钥匙，翻了 5 个地方，有没有翻对？

3、生成：

指标名称	含义说明	工具/方法	举例
F1 Score	是否答对了关键词/核心事实	与标准答案对比 (token级)	$F1=2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$
Exact Match	模型生成内容是否逐字逐句与参考答案一致	0/1标记	用户问题：“中国的首都是哪里？”，答案一个字都不能错
高级模型 (如GPT) 评审打分	通过 GPT 评估回答是否 有用、正确、结构清晰	Prompt GPT-4 做 评分	GPT打分示例：3分，理由：回答正确但过于啰嗦，建议精简
幻觉率	生成内容中是否包含未出现在 retrieved context 中的事实或内容	判断回答内容是否来自提供的 context；GPT评分、人工评价	用户问：“张三的信用额度是多少？”，文档中无提及，但模型答“50,000 元”
可读性评分	回答是否自然、流畅 (非硬生成)	GPT评分、人工评价	“很抱歉您的账单尚未生成，建议明日再次查询。” “账单生成今天不能查询”

3.2 RAG/问答系统的生成质量评估标准，不是通用的，而应结合具体场景定制

(1) 一般通用维度：

维度	问题	关注点
准确性	回答内容是否真实可靠？是否包含幻觉？	有没有事实性错误？是否引用了错文档？
完整性	回答是否涵盖了核心信息点？是否答全了？	漏掉关键信息会误导用户吗？
表达清晰度	语言是否通顺自然？用户是否能看懂？	有没有歧义、跳跃、逻辑混乱？
引用/可溯源性	答案是否基于知识库内容？是否引用了文档？	能否反查证据、提高信任度？
安全/合规性	内容是否可能引发误导、违规、越权？	尤其是医疗/金融类回答是否“踩线”？

(2) 用你的实际场景去套用

如医疗知识问答：

维度	评分说明	样例说明
准确性（权威性）	是否基于权威医学知识，是否与医学文献一致	 “感冒可以自愈” vs  “大多数普通感冒7天内可自行缓解”
完整性	是否涵盖了症状、成因、处理建议、何时就医等要点	只说“多喝水”是不够的，应包含“何时该去医院”等内容
表达清晰度	是否用非专业人士能理解的语言表达医学概念	“呼吸困难可能涉及多种病因，包括感染、哮喘或心血管问题”
安全性（合规性）	是否谨慎避免给出“诊断结论”，是否加适当免责声明	应有表述：“以下内容仅供参考，不能代替医生诊疗意见”
引用可靠性	是否标注出处，或是否能清晰说明信息来源于哪个资料/知识库段落	来自《中国居民营养指南2022》 or “健康百科/常见病答疑”

如电商客服问答系统中，客服回答有没有“挽留用户”、减少流失

代码块

- 1
- 电商客服的目标不是答完，而是‘让用户满意’、‘让订单别退’、‘让客气别断’。
- 2
- 所以评估生成质量时，不只是看对错，更要看有没有温度、有没有挽留。”

维度	评估目标	是否通用
准确性	回答是否真实、专业、符合平台规则（例如退货政策、退款流程）	✓
表达清晰度	回答是否逻辑通顺、结构合理、语义清楚	✓
服务语气与态度	回答是否有耐心、礼貌、情绪稳定、具备安抚性	✓（行业需强调）
用户挽留能力	回答中是否尝试积极沟通、提出解决方案，避免“放弃型答复”	！关键业务指标（1）主动安抚：有没有表达理解、缓解情绪？ （2）提出替代方案：有没有给出解决思路/替代路径/优惠补偿？； （3）避免放弃话术：有无直接“推走用户”的话术，例如“我们不处理”、“去联系快递公司”等
满意度导向	回答是否引导用户正面情绪转化，如“感谢反馈，我们马上处理”是否到位	✓

用户挽留能力：

子维度	说明	举例评价
主动安抚	有没有表达理解、缓解情绪？	“很抱歉给您带来不便，我们非常理解您的情况……”
提出替代方案	有没有给出解决思路/替代路径/优惠补偿？	“我们可以为您加急退款，或提供优惠券作为补偿……”
避免放弃话术	有无直接“推走用户”的话术，例如“我们不处理”、“去联系快递公司”等	✗ “我们无法处理，请您找快递” ✓ “我们来协助您联系快递公司”


4、微调 RAG 选择逻辑

4.1 微调 VS RAG 打个比方

Fine-Tuning



RAG



(1) 微调 = 考前死记硬背，靠记忆答题

- 你不能带资料！
- 全靠自己“记住了啥”来作答。

(2) **RAG** = 考试时偷偷带了小抄，边查边答题

你把整本教材和重点资料做成小抄（知识库）；考试时，一看题目就快速翻小抄找到答案相关内容；然后再组织语言答题。

在实际应用落地中，能不做微调就不做微调，能用RAG先验证效果，用得好再谈定制微调
(绝大部分公司搞不起微调)

4.2 微调适用场景：

问题	回答
有无标注数据？	没有 → 先别上微调
有无高性能显卡？	没有 → 训练不了
是否具备训练/部署经验？	没有 → 运维风险高
是否是 高强监管/高风险领域 ？	✅ 是 → 但是要找场景，并评估微调成本

代码块

- 1
- 2
- 3
- 4
- 5
- 6
- 7
- 8
- 9
- 10
- 11
- 12
- 13
- 14
- 15
- 16
- 17
- 18
- 19
- 20
- 1、对结果“准确率”要求极高的生产级应用**
高精度要求的垂直领域（如医疗、法律、金融），普通大模型往往“一知半解”。
通过微调让模型“考取专业证书”，是必要手段。
比如**医疗问答微调后能够准确识别病因、建议更具指导**
 - 2、想要定制独特的“风格/语气/结构”**
你希望模型的回答总是符合你品牌调性？
比如电商客服一定要礼貌、有情绪缓冲、话术规范；或你希望回答永远遵循“定义-分析-建议”的结构，**这就可以通过微调实现行为模式的固化。**
 - 3、模型需要处理“边缘案例”或冷门问题**
数据稀缺、不具代表性、通用模型根本没见过、无法泛化的稀有问题（如：老旧设备报错信息、少数民族语义理解等），**微调是一种弥补通用模型短板的策略。**
 - 4、想把大模型“压缩”成可控成本的小模型**
用大模型生成训练数据（teacher） → 用这些数据去训练或微调一个小模型（student）
比如：
（1）用 GPT-4、Claude 3、Gemini 等大模型构造“用户问题+答案”数据集
（2）用这些数据去训练小模型比如LLaMA-2 7B、Mistral、ChatGLM，模仿大模型的输出风格和逻辑

4.3 落地步骤决策：



（1）先用RAG + 通用模型验证：

快速上线原型、观察效果是否满足需求；成本低、上线快

（2）特定场景能力强化可考虑微调：

如意图识别不准 → 微调分类模型

【举例】

1、面向用户的“感冒类症状问诊问答”

代码块

- 1
- 用户可以输入日常身体不适的描述，AI会给出初步判断和建议，帮助用户在“需不需要就医”“适不适合吃药”“什么症状是异常”等问题上获得指导

比如用户提问：

代码块

- 1
- 我这两天喉咙痛，有点发烧，是感冒还是流感？”
- 2
- “嗓子有痰但不咳嗽，是不是问题不大？”
- 3
- “宝宝38度发烧要不要立刻去医院？”
- 4
- “我吃了感冒药怎么还没好？”

如果只用通用大模型

问题类型	示例	问题描述
回答模糊/含糊其辞	“建议您关注症状变化并根据需要就医”	听起来是废话，用户不知所措
医学术语难理解	“可能为上呼吸道感染，注意区别病毒性与细菌性”	普通用户难以理解
场景判断错误	宝宝发烧问题被当成成年人对待	误导严重，可能延误就医
信息不合规或幻觉	模型自由生成“推荐某某药”，但该药不能随便使用	涉及违规用药推荐，存在法律风险

所以需要通过微调：答得准”、“说得清”、“不能乱讲”

维度	微调实现什么目标？
内容安全边界控制，避免幻觉	微调时可明确设定“不得推荐具体药品”、“不得给出确诊结论”，避免医疗风险
问诊模版固化	可训练出固定的问诊模板，例如：识别症状 → 区分人群（儿童/老人） → 给出非药物建议 → 必要时推荐就医
风格统一与信任感	比如始终用“您好～”开头、“希望您早日康复”结尾，更像是专业健康助手在说话，而不是“生成式AI”在答题

2、智能设备上微调

(1) 资源受限，需要小模型高性能

代码块

- 1 智能手表、智能音箱、车机、眼镜等设备不能承载GPT-4这种大模型。
- 2 所以要训练一个轻量但适配场景的小模型
- 3 响应速度更快、不依赖网络、隐私更安全

(2) 场景非常垂直，泛化模型理解不了

代码块

- 1 “打开空气模式”
- 2 “把灯光调成晚安模式”

3、电商客服自动回复 “定制回复内容”

固定任务有：咨询商品退换货、物流查询、发票等问题

用户提问	模型输出要求（高一致性）
“如何退货？”	结构要求：礼貌+规则+操作路径（不能乱说） 比如： 您好，感谢您的咨询！ 根据平台规则，您可在商品签收后7天内申请退货，前提是商品未拆封且不影响二次销售。 【退货操作路径】：请您进入“我的订单”>选择对应商品>点击“申请售后”>选择“退货退款”并填写原因和图片，即可提交退货申请。 如遇到操作问题，您也可以拨打客服热线 400-XXX-XXXX 或通过App在线客服获取帮助。 祝您生活愉快！
“你们发票开不了怎么办？”	回答要含“开票入口位置+支持类目+客服电话”等要点，比如 您好，关于发票问题为您说明如下： 【开票入口位置】：请您打开App首页，点击“我的订单”>选择需要开票的订单>点击“申请开票”进行操作。 【开票支持类目】：目前平台支持电子发票开具，部分虚拟类商品（如会员充值、部分优惠券）暂不支持开票，具体请以页面提示为准。 如系统提示“开票失败”或长时间未收到发票，请拨打客服热线 400-XXX-XXXX 或在App内联系客服，我们将协助您处理。 感谢您的理解与支持！

微调后模型可以**确保**：

- 每一句都以“您好”开头
- 内容格式标准、字段不漏、话术不变
- 情绪稳定、避免攻击性或冷漠语言
- 每次回答后都要自然地补充一句服务引导语，例如：“感谢您的理解与支持！”。

如果你只用prompt：

固定语句易被遗漏：模型并不总能稳定添加结尾引导语或者是开头引导语

情感容易出现波动：例如“富有同理心”这类主观性风格，模型可能一会儿过于煽情，一会儿又显得冷淡，呈现出风格波动。

4、RAG 为什么更能降低幻觉率？（对于高精度场景，rag和微调可以配合使用）

模型类型	机制	风险
纯生成模型（如 GPT 微调后）	直接基于训练参数“记忆”回答	有可能编造、脱离实际业务/法规
RAG 模型	先“检索真实文档”，再基于结果生成回答	生成有据可依，幻觉显著降低

举例：

代码块

1

用户问：“如何在我们行申请公积金贷款？需要准备什么材料？”

2

3

微调模型可能回答：“请携带身份证、户口本和结婚证前往柜台办理。”（听起来对，其实可能不需要结婚证）

4

RAG 模型先检索“贷款指南文件”，然后引用其内容回答，内容来源明确，准确率高

4.4 RAG 微调 Prompt的选择问题

1、微调-“记忆力”；RAG-“查资料”；Prompt-“提示词”

方法	类比说明
RAG	你不会死记硬背，但你考试带“小抄”，现场查资料答题
微调	你改了大脑和行为，变得能做之前做不到的事
Prompt	你只是提醒自己“用某种口气/格式”说话，比如“用英文说一下”（这种相对简单明确的场景）

2、对比

维度	RAG（检索增强生成）	微调（Fine-tuning）	Prompt 工程（Prompt Engineering）
知识来源	外部知识库（实时检索）	模型内部记忆（参数中学习到过的）	模型已有知识，外部提示“怎么说”
作用方式	检索文档 → 结合内容生成	修改模型权重 → 改变行为/理解	添加指令或上下文 → 改变模型生成输出风格/方式
是否训练模型	✗ 不训练，直接用	要训练（甚至反复微调）	✗ 不训练模型，只改提示词
更新频率	灵活，知识库一改就生效	训练后静态，更新需重训	即时修改，改Prompt就行

3、举例

任务类型	外部知识需求	行为改动需求	推荐方法
问政策、查手册、答更新文档	高	低	✓ RAG
控车、调灯、换说法	低	高	✓ 微调
改语气、改格式、写特定写作风格（简单版）	低	低	✓ Prompt 工程

5、关于coze 中索引的问题

在检索时，只会围绕索引这一列的内容去匹配用户的问题，而不是整张表都参与。

举例：

产品名称	品牌	型号	售价	售后政策
空气炸锅	美的	MZ-230	399元	7天无理由，保1年
电热水壶	九阳	JY-K123	199元	只换不修1年

在coze中，我只能指定一个字段如“产品名称”作为索引字段。

带来的问题：用户以下提问没办法被解决：

代码块

- 1 “MZ-236的售后怎么处理？”（问型号）
- 2 “九阳的电热水壶退货流程？”（品牌+品类）
- 3 “399那个锅能换吗？”（价格+产品）

品牌、型号、价格出现在 Excel 的其他字段中，由于 Coze 只能用一个字段当索引，就会造成检索精度不够、召回失败的问题