

场景篇

AI核心技术与产品场景深度融合

2: 企业级大模型应用产品

架构方式



上节回顾



1:确认输出
目标



2:初步确认
输入场景

3:设计LLM
处理



核心框架：CRISPE框架

APB



五层结构
APB

逻辑

角色

任务目标

用户层

UE、UI

产品经理
UI、UE

良好的用户体验

简洁提问

用户需要的答案

驱动动作结果

应用层

专业提示词

专业回答

提示词工程师
(产品经理部分兼任)

1: 提示词结构化便于开发
2: 提示词技巧提高回答确定性可控性

检索增强
RAG
易读知识库
结构化数据

接口调用
MCP
Function call

研发主导，产品辅助

1: 知识库导入、分块、向量化处理，
建索引、检索
2: RAG能力评测

动作驱动

模型层

垂直大模型

大模型厂商、算法工程师

提升模型泛化能力或者垂直能力
准确性、易用性、成本控制

通用大模型

数据层

丰富可靠的数据湖

大模型厂商+大数据提供方+客户

提供数据
构建大模型易读的公、私数据系统

算法算力层

算法

算力

AI科学家、芯片厂商

提升算法算力水平

大模型
(LLM)

智能体
(Agent)

提示词
(Prompt)

工作流
(Workflow)



CONTENTS

目录

A I · 产 品 · 商 业

01

大模型产品设计梳理过程

02

Rag、Function call结构设计

03

微调的概念和适用场景

Part One

01


大模型产品设计梳理过程



1:确认输出
目标

2:初步确认
输入场景

3:设计LLM
处理





流程

角色

结构



流程

角色

结构



- 大模型产品的常规方式
 - 复刻人的决策方式
 - 复刻人的组织流程
- 因此
 - 首先梳理原有业务，人工处理的方式和逻辑



这个步骤的关键

APB



- 机械时代
 - 把人工流程，人手工艺，复刻到机器上
 - 提升效率和和精度
- AI时代
 - 把人工流程，人脑工艺，复刻到智能体
 - 提升效率和和精度



- 商品自动选品发微博



大致流程如下

APB



我们思考下，人工的话一般几个分工，什么流程

APB



看热点新闻



每条新闻分析，从商品
库找到适合的商品



根据热点和新闻撰
写适合平台的文案

根据热点和新闻制
作适合平台的视频



发布内容



- 流程通过工作流复刻



个人万能助理

单 Agent (自主规划模式)

草稿自动保存于01:39:48

发布

人设与回复逻辑

编排

预览与调试

提示词

模型设置

模型

模型选择

豆包·1.5·Pro·32k

技能

插件

工作流

workflows

知识

扣子

文本

表格

照片

记忆

变量

数据库

长期记忆

文件盒子

对话体验

推荐

个人

通用结构

任务执行

角色扮演

适用于多种场景的提示词结构，可以根据具体需求

适用于有明确的工作步骤的任务执行场景，通过明

适用于聊天陪伴、娱乐场景，可

工作流

shangye_card

生成商业知识卡片，调用此工作流，组合生成一张图片

发送消息...

- 标准说法：工作流（Workflow）是一套流程化的系统，包含多个步骤，可以调用不同的大模型，API，用于回答问题或完成某项任务
- 通俗理解
 - 工作流就是一个流水线，把各种工具（比如大模型、接口、脚本）等按照一定的顺序连接起来，完成一个复杂任务



- 智能体（Agent）像一个助理，或者像一个人
 - 更加灵活的选择适合的流水线或者自己手工操作这些工具完成目标
- 工作流（workflow）更像一条生产线
 - 一丝不苟的按照既定的流程完成工作
- 所以
 - 智能体更灵活，而工作流更有确定性
 - 工作流的优势在于可以方便的集成整合各种能力
 - 而智能体可以灵活的调用工作流




- 智能体是LLM面向对象最终的产品
- workflow是智能体中完成某一工序的流水线
- 类似:
 - 微信是个智能体
 - 扫描二维码识别是一个 workflow
 - 搜索公众号文章是一个 workflow




人工流程和工作流组件的关系

APB




大致看一下在Coze中的体现

APB




人工流程和工作流组件的关系

APB



新闻抓取器

APB



- 从搜狐上抓取热点新闻
- 返回新闻列表

top_news 真实数据 ▶ ... ✕

帮助用户获取搜狐网上的每日热闻

单次

批处理

▼ 输入 ⓘ

变量名	变量值
count*	int. 10
q	str. 输入或引用参数值

▼ 输出 ⓘ

查看示例

```
data Object
└─ coze_ark_001 Object
    └─ list Array<Object>
```


运行结果

APB

输出

```
> data {1}
  message : "success"
  total : 0
  traceId :
    "dcc4af9285bb42dcb4ad0eb3c56311b6.125049.176948
    12194883979"
  code : 0
  success : true
```

brief : "亚滴公司，未对可用于营运的车辆承租人员进行排查，未及时发现承租人员不具有营运资质的隐患，未落实生产安全事故隐患排查治理制度，未采取技术、管理措施，及时发现并消除事故隐患，违反了《中华人民共和国安全生产法》相关..."

title : "广州一曹操出行网约车连撞八车致1死4伤 事故调查报告：司机带病驾驶且无从业资格"

url :
"https://www.sohu.com/a/980427716_260616?trans=000020_cozecj"

> 1 {3}

brief : "美国总统特朗普在2025年1月20日就任当天签署行政令，宣布美国将退出《巴黎协定》。对于美国退出《巴黎协定》一事，联合国秘书长副发言人哈克日前在回答央视记者提问时表示，所有国家都必须履行应对气候变化的义务，反..."


title : "视频 | 美正式退出《巴黎协定》 联合国：反对任何逃避气候承诺的做法"

url :
"https://www.sohu.com/a/980426290_162522?trans=000020_cozecj"

> 2 {3}


人工流程和工作流组件的关系

APB



构建一个循环

APB



- 有多少条新闻，干多少次活

循环

用于通过设定循环次数和逻辑，重复执行一系列任务。

循环设置

循环类型 ⓘ

使用数组循环

循环数组 ⓘ


变量名	变量值
input	<code>{}</code> top_news - list

中间变量 ⓘ

变量名	变量值	变量类型
output	文案专家 - 0.	Array<String>

人工流程和工作流组件的关系

APB



流程

角色

结构





- 用Prompt复刻在这个位置上的人
- 他的
 - 人设
 - 能力
 - 工作流程
 - 风格
 -



核心框架：CRISPE框架

APB





- 看新闻，分析出需要什么样的商品进行匹配

输入

变量名	变量值
cate	str. 循环 - title
word	str. 循环 - brief

视觉理解输入

变量名	变量值
-----	-----

系统提示词

角色：商品匹配师
你是一个从新闻中寻找适合商品的选品专家，擅长找到新闻和商品之间的关联

目标：
阅读新闻，分析新闻中的内容可以对应怎样的商品，例如，天气降温，可以对应保暖衣物

技能：
1. 阅读新闻标题{{cate}}和新闻内容{{word}}
2. 思考分析这样的新闻可以对应怎样的商品，重点放在食品分类
3. 给出对应商品的关键词

工作流：
1. 阅读新闻标题{{cate}}和新闻内容{{word}}
2. 思考分析这样的新闻可以对应怎样的商品，重点放在食品分类

系统提示词

角色：商品匹配师

你是一个从新闻中寻找适合商品的选品专家，擅长找到新闻和商品之间的关联

目标：

阅读新闻，分析新闻中的内容可以对应怎样的商品，例如，天气降温，可以对应保暖衣物

技能：

1. 阅读新闻标题{{cate}}和新闻内容{{word}}
2. 思考分析这样的新闻可以对应怎样的商品，重点放在食品分类
3. 给出对应商品的关键词

工作流：

1. 阅读新闻标题{{cate}}和新闻内容{{word}}
2. 思考分析这样的新闻可以对应怎样的商品，重点放在食品分类上
3. 给出对应商品的关键词

输出格式：

文本

限制：

- 只输出商品关键词，不要涉及其他内容
- 如果对应不出来商品，则输出“没有对应内容”
- 描述角色在互动过程中需要遵循的限制条件3



输入

cate : "广州一曹操出行网约车连撞八车致1死4伤事故调查报告：司机带病驾驶且无从业资格"

word : "亚滴公司，未对可用于营运的车辆承租人员进行排查，未及时发现承租人员不具有营运资质的隐患，未落实生产安全事故隐患排查治理制度，未采取技术、管理措施，及时发现并消除事故隐患，违反了《中华人民共和国安全生产法》相关..."

技能调用

输出

output : "没有对应内容"

输入

cate : "11岁男孩打碎电视屏，在小区创业“还债”，2个月
后....."

word : "尧哥自己写了一张“求职广告”，上面开设的语文、数学、田径、足球、钢琴课程都是他擅长的科目和兴趣爱好，还写明了“创业”背景：每天放学后，尧哥上门辅导其他孩子写作业，或在小区草坪上开展足球教学，周末排得也满满当当..."

技能调用

输出

output : "能量补充零食、运动饮料、健脑食品"

本次批处理变量

> input {3}

输入

cate : ""“太原酒厂董事长涉嫌殴打他人”山西太原通报：已停职检查"

word : "1月27日，山西太原市国资委发布情况通报：近日，有媒体反映太原酒厂董事长涉嫌殴打他人并被行政拘留的情况。太原酒厂系我委监管企业，我委对此高度重视，已第一时间组织相关部门召开专题会议，并同步启动核查。经初步核查..."

技能调用

输出

output : "太原白酒"

人工流程和工作流组件的关系

APB



Part Two


02

Rag、Function call结构设计

流程

角色

结构



- 用什么样的结构满足需求
- 内部信息、规则、提升精度、降低幻觉
 - RAG
- 调用结构化数据库，调用接口
 - Function calling、MCP
- 语气调整、提升精度、降低幻觉
 - 微调



人工流程和工作流组件的关系

APB



- 做一个智能电商客服机器人，需要怎么做？
- 电商客服几个核心场景
 - 商品介绍
 - 售后客诉
 - 订单查询
- 周边功能
 - 情感化
 - 语言风格
 - 长期记忆



- description: 我是一名具有十年以上经验的在线客服专家，专门处理女装产品的售前、售中、售后问题。我能够提供准确、及时的解答，帮助解决您的问题。

Goals:

1. 理解并回答您的女装产品售前、售中、售后问题
2. 根据您的反馈和需求进行服务的迭代优化
3. 提供准确、清晰、易于理解的解答，以优化用户体验 ##Rules: 对千无法确定的问题，必须回复固定内容"亲，很抱歉，我不明白您的意思，麻烦您简要描述您的问题~"

Skills:

1. 深度理解您的女装产品问题，准确推测出对应的需求场景
2. 提供准确、清晰、易于理解的解答，以优化用户体验
3. 根据您的反馈和需求进行服务的迭代优化

Workflow:

1. 深入理解您的女装产品问题，分析其对应的需求场景
2. 提供符合规范和标准的解答
3. 根据您的反馈和需求进行服务的迭代优化
4. 对每一个提供的解答进行严格的测试和校验，以确保其符合您的需求和期望
5. 在需要的情况下，进行多轮的解答修订和优化，以确保最终的解答完全符合您的需求

Initialization:

作为<Role>，必须遵循<Rules>，必须在默认<Language>与您进行互动。我会先以友好的方式欢迎您，并向您详细介绍我如何能够帮助您。我会告诉您我将按照<workflow>来帮助您，并确保您的问题得到解决。

- 智能体
 - 提供的技能
 - 角色特点
 - 核心目标
 - 回答边界



- Prompt 只能解决大模型在预训练过程中已经存在的东西
- 但是
 - 如果一个问题，在大模型中没有答案会怎样
 - 会胡说八道，且态度非常自信
 - 大模型幻觉



- 公司内部的规则
- 例如：
 - 退换货规定
 - 产品说明
 - 产品详细介绍
 - 等属于公司内部知识的内容，在大模型预训练中不存在的
- 用RAG解决



- RAG
 - (Retrieval-Augmented Generation, 检索增强生成)
- 核心工作流程
 - 存储信息：把大量的文档（比如文章、报告）转化成向量，进行存储
 - 匹配问题：当你提出问题时，AI会把问题也变成向量，然后在信息库中找到与之最匹配的内容
 - 生成答案：最后，AI把这些匹配的内容和你的问题一起交给大语言模型（LLM），生成一个更准确的回答



- 例如：
 - 运维智能体
 - 响应应急事件，进而进行故障诊断，然后故障复盘，进而进行经验沉淀
 - 医疗智能体
 - 根据病患的情况，基于病例库，进行反馈
 - 投资分析
 - 利用既往数据和实时手机进行市场研判
- 本质：
 - 有自己数据资产的，要形成更精准或者更具特色的业务场景



创建知识库

APB

创建知识库

×

知识库创建方式 *

关联火山知识库
支持文本、表格知识库，精细化切片管理，适合企业客户场景，费用由火山方舟收取，暂不在积分抵扣范围

创建扣子知识库
支持图片、文本、表格知识库，智能切换管理，适合轻量检索场景

文本格式

表格格式

照片类型

名称 *

输入数据集名称

0/100

描述

输入数据集内容的描述

0/2000

导入类型

本地文档

上传 PDF, TXT, MD, DOC...

自定义

自定义内容，支持创建&编辑

在线数据

获取在线网页内容

公众号

导入公众号到知识库中

Notion

将 Notion 页面和数据库导...

飞书

导入飞书文档到知识库

图标

取消

完成创建

创建并导入

名称 *

输入数据集名称

0/100

描述

输入数据集内容的描述

0/2000

导入类型

本地文档

上传Excel或者CSV格式的...

自定义

自定义内容，支持创建&编辑

API

获取JSON格式API内容

飞书

导入飞书表格到知识库

图标

自动保存 电商模拟数据 200 数据

开始 插入 绘图 页面布局 公式 数据 审阅 视图 自动化 Acrobat

等线 (正文) 12 B I U 背景色 前景色 插入表格 删除表格 条件格式 套用表格 单元格式


可能的数据丢失 如果将此工作簿以逗号分隔 (CSV) 格式保存，则某些功能可能会丢失。若要保留这些功能，请以 Excel 文件格式保存。

	A	B	C	D	E	F	G	H	I	J	K	L
1	商品名称	价格	分类	详情	最近一个月	退货率	毛利率					
2	手工坚果礼	182.52	食品	保质期8个月，健康美味	974	4.75%	42.90%					
3	定制八音盒	807.92	礼品	品质保证，适合商务馈赠	1914	8.34%	41.93%					
4	网红咖啡豆	180.8	食品	保质期8个月，健康美味	1638	4.25%	27.53%					
5	轻奢钥匙扣	892.83	礼品	送礼首选，适合纪念日	1011	5.71%	44.04%					
6	网红燕麦片	145.99	食品	保质期11个月，健康美味	4705	3.34%	33.80%					
7	高端摆件	714.15	礼品	设计独特，适合节日	654	13.46%	45.01%					
8	家庭装薯片	274.74	食品	保质期8个月，回购率高	4981	4.20%	33.13%					
9	简约手办	837.02	礼品	送礼首选，适合纪念日	619	4.70%	33.01%					
10	进口曲奇饼	44.14	食品	保质期8个月，口感极佳	1606	2.94%	24.91%					
11	简约手办	232.97	礼品	设计独特，适合商务馈赠	1574	7.53%	69.23%					
12	美味巧克力	213.77	食品	保质期11个月，口感极佳	3395	1.47%	32.45%					
13	轻奢手办	468.51	礼品	送礼首选，适合商务馈赠	341	4.22%	59.95%					
14	有机坚果礼	165.49	食品	保质期8个月，健康美味	2805	4.59%	34.54%					
15	限量马克杯	97.88	礼品	包装精美，适合纪念日	1456	4.56%	31.77%					
16	有机水果软	168.18	食品	保质期4个月，精选原料	420	4.43%	26.98%					
17	节日盲盒公	785.31	礼品	包装精美，适合生日	1772	5.53%	34.10%					
18	特产水果软	119.13	食品	保质期9个月，回购率高	2927	1.75%	15.91%					
19	限量装饰画	994.47	礼品	设计独特，适合节日	421	12.91%	66.69%					
20	进口咖啡豆	154.66	食品	保质期9个月，精选原料	2220	4.02%	40.89%					
21	可爱盲盒公	838.96	礼品	设计独特，适合生日	590	14.45%	44.84%					
22	传统普洱茶	194.96	食品	保质期3个月，精选原料	4442	2.36%	43.78%					
23	可爱盲盒公	338.48	礼品	设计独特，适合纪念日	271	6.72%	58.70%					
24	手工巧克力	160.08	食品	保质期5个月，口感极佳	2436	1.63%	37.20%					
25	简约摆件	123.05	礼品	送礼首选，适合纪念日	360	7.34%	38.97%					
26	进口坚果礼	261.26	食品	保质期5个月，口感极佳	4362	3.84%	29.24%					

	商品名称 索引 String	价格 Number	分类 String	详情 String	最
1	手工坚果礼盒 930款	182.52	食品	保质期8个月，健康美味	95
2	定制八音盒 223款	807.92	礼品	品质保证，适合商务馈赠	19
3	网红咖啡豆 759款	180.8	食品	保质期8个月，健康美味	16
4	轻奢钥匙扣 674款	892.83	礼品	送礼首选，适合纪念日	10
5	网红燕麦片 513款	145.99	食品	保质期11个月，健康美味	45
6	高端摆件 871款	714.15	礼品	设计独特，适合节日	65
7	家庭装薯片 511款	274.74	食品	保质期8个月，回购率高	45

搜索商品库，找对应商品

APB



- 从商品库中找对应商品

输入 ⓘ

变量名 变量值

Query* String str. 商品匹配专家 - out... × ⓘ

知识库 ⓘ

知识库来源 扣子知识库

目标知识库 商品

搜索策略 ⓘ 语义

最大召回数量 ⓘ 1 Default 20

最小匹配度 ⓘ 0.01 Default 0.99

☒ 表格 SQL 查询

123458

本次批处理变量

> input {3}

输入

cate: "澳网卫冕冠军遭淘汰出局, 还得吃闺蜜指定的"黑暗料理"

word: "极目新闻记者陈凌燕佩古拉晋级 (视频截图) 1月26日, 2026澳大利亚网球公开赛女单第四轮, 卫冕冠军凯斯以0-2不敌好闺蜜佩古拉, 不仅伤心出局, 还得去吃下一款"黑暗料理"。凯斯和佩古拉是好朋友, 在场外, 两人一起..."

技能调用

输出

output: "黑暗料理食品"

总数: 10只看错误

123458

本次批处理变量

> input {3}

输入

Query: "黑暗料理食品"

chatHistoryRound: 3

enableChatHistory: false

输出

outputList {1}

0 {2}

output: "{\\"价格\\":\\"12\\",\\"分类\\":\\"食品\\",\\"最近一个月销售量\\":\\"900\\",\\"毛利率\\":\\"21%\\",\\"详情\\":\\"黑暗料理类似产品\\",\\"退货率\\":\\"15%\\",\\"商品名称\\":\\"黑暗料理\\"}"

documentId: "7599521983205736448"



五层结构详解

APB

逻辑

角色

任务目标

用户层

UE、UI

产品经理
UI、UE

良好的用户体验

简洁提问

用户需要的答案

驱动动作结果

应用层

专业提示词

专业回答

提示词工程师
(产品经理部分兼任)

1: 提示词结构化便于开发
2: 提示词技巧提高回答确定性可控性

检索增强
RAG
易读知识库
结构化数据

接口调用
MCP
Function call

研发主导，产品辅助

1: 知识库导入、分块、向量化处理，
建索引、检索
2: RAG能力评测

动作驱动

模型层

垂直大模型

大模型厂商、算法工程师

提升模型泛化能力或者垂直能力
准确性、易用性、成本控制

通用大模型

数据层

丰富可靠的数据湖

大模型厂商+大数据提供方+客户

提供数据
构建大模型易读的公、私数据系统

算法算力层

算法

算力

AI科学家、芯片厂商

提升算法算力水平

五层结构详解

APB

逻辑

角色

任务目标

用户层

UE、UI

产品经理
UI、UE

良好的用户体验

简洁提问

用户需要的答案

驱动动作结果

应用层

专业提示词

专业回答

提示词工程师
(产品经理部分兼任)

1: 提示词结构化便于开发
2: 提示词技巧提高回答确定性可控性

检索增强
RAG
易读知识库
结构化数据

接口调用
MCP
Function call

研发主导，产品辅助

1: 知识库导入、分块、向量化处理，
建索引、检索
2: RAG能力评测

动作驱动

模型层

垂直大模型

大模型厂商、算法工程师

提升模型泛化能力或者垂直能力
准确性、易用性、成本控制

通用大模型

数据层

丰富可靠的数据湖

大模型厂商+大数据提供
方+客户

提供数据
构建大模型易读的公、私数据系统

算法算力层

算法

算力

AI科学家、芯片厂商

提升算法算力水平

建立一个agent: 个人职场助理

APB



没有RAG的反应

APB



用户MTkwW4

需要做一款新产品，本地生活方向，目标是提升收益



个人职场助理

目前我还缺少部门发展目标和您岗位的 KPI 信息，这对全面分析工作逻辑和制定计划很关键，请您补充这些内容。不过，我先初步拆解一下“做一款本地生活方向新产品并提升收益”这个工作的核心要点和可能存在的问题：

核心要点

- 市场调研：**了解本地生活市场的需求、竞争态势、消费者偏好等，为产品定位提供依据。
- 产品定位：**明确产品的目标用户群体、核心功能和价值主张，使产品具有差异化竞争优势。
- 产品开发：**根据定位进行产品的设计、开发和测试，确保产品的质量和用户体验。
- 营销策略：**制定有效的推广方案，提高产品的知名度和曝光度，吸引用户使用。
- 用户运营：**关注用户反馈，持续优化产品，提高用户满意度和忠诚度，促进用户的二次消费和口碑传播。
- 收益管理：**合理制定产品价格，控制成本，通过多种盈利模式实现收益增长。

可能的问题点

- 市场竞争：**本地生活市场竞争激烈，新产品可能面临来自已有竞争对手的压力。
- 用户获取：**如何吸引目标用户使用新产品，提高用户注册和使用率是一个挑战。
- 产品迭代：**需要及时根据用户反馈和市场变化进行产品迭代，否则可能导致用户流失。
- 盈利模式：**确定合适的盈利模式并实现盈利需要一定的时间和市场验证。

策略方案（初步）

- 市场调研阶段：**采用线上问卷、线下访谈、竞品分析等方式，全面了解本地生活市场情况。
- 产品定位阶段：**结合调研结果，聚焦目标用户的痛点和需求，打造具有特色的产品。
- 产品开发阶段：**与技术团队紧密合作，确保产品按时上线，并进行严格的测试。
- 营销推广阶段：**利用社交媒体、线下活动、合作推广等多种渠道进行宣传，吸引用户。
- 用户运营阶段：**建立用户反馈机制，定期举办用户活动，提高用户参与度。
- 收益管理阶段：**根据产品成本 and 市场需求，灵活调整价格策略，探索多种盈利途径。

待您提供部门发展目标和岗位 KPI 后，我将进一步完善分析和计划。



用户MTkwW4

部门目标：季度目标 1000w 收入，岗位 kpi：设计新产品或者完善老产品，提升 dau



个人职场助理

工作逻辑分析

部门有季度 1000w 收入的目标，而您的岗位 KPI 聚焦在产品层面，通过设计新产品或完善老产品来提升日活跃用户数（DAU）。其内在逻辑在于，新产品的推出或老产品的优化能吸引更多用户使用，增加用户的活跃度，进而提高用户的消费意愿和频率，最终为部门实现季度收入目标做出贡献。因为只有用户活跃起来，才更有可能产生交易，从而带来收入。

核心要点拆解

1. 产品洞察

- 深入了解本地生活市场的需求、痛点和趋势，以便设计出符合市场需求的新产品或对老产品进行针对性的优化。
- 分析竞争对手的产品特点和优势，寻找差异化竞争的机会。

2. 产品设计与优化

- 运用设计思维和用户体验原则，打造具有吸引力和易用性的产品功能和界面。
- 对于新产品，要确保其核心价值清晰，能够解决用户的实际问题；对于老产品，要根据用户反馈和数据分析，有针对性地改进功能和体验。

3. 用户增长策略

- 制定有效的用户获取和留存策略，通过线上线下的营销活动、社交媒体推广、口碑传播等方式，吸引新用户并留住老用户。
- 关注用户的行为数据，分析用户流失的原因，采取相应的措施进行优化。

4. DAU 提升

- 设定合理的 DAU 增长目标，并将其分解到具体的时间段和工作任务中。
- 通过优化产品的推送机制、增加用户互动功能、举办限时活动等方式，提高用户的每日活跃度。

需要注意的要素

- 用户体验：**产品的设计和优化要始终以用户为中心，确保用户在使用过程中能够获得良好的体验，否则即使吸引了用户，也难以留住他们。
- 数据驱动：**在整个工作过程中，要充分利用数据分析来指导决策。通过对用户行为数据、市场数据的分析，了解产品的优势和不足，及时调整策略。
- 跨部门协作：**为了实现部门的收入目标和提升 DAU，需要与市场、销售、运营等部门密切协作。例如，市场部门负责产品的推广，销售部门负责将用户转化为付费客户，运营部门负责维护用户关系。

构建一个知识库

APB

知识

扣子知识库

自动调用

文本

+

将文档、URL、三方数据源上传为文本知识库后，用户发送消息时，智能体能够引用文本知识中的内容回答用户问题。

表格

+

照片

+

创建知识库

知识库创建方式 *

关联火山知识库

支持文本、表格知识库。精细化切片管理，适合企业客户场景，费用由火山方舟收取，暂不在资源点抵扣范围

创建扣子知识库

支持图片、文本、表格知识库，智能切换管理，适合轻量检索场景

知识库类型

文本格式

表格格式

照片类型

名称 *

大模型应用案例7/100

描述

输入数据集内容的描述0/2000

导入类型

本地文档

上传 PDF, TXT, MD, DOC...

在线数据

获取在线网页内容

飞书

导入飞书文档到知识库

公众号

导入公众号到知识库中

Notion

将 Notion 页面和数据库导...

自定义

自定义内容，支持创建&编辑

图标

取消

完成创建

创建并导入

上传文档-开始创建

APB

1

上传

2

创建设置

3

分段预览

4

数据处理



点击上传或拖拽文档到这里

支持 PDF、TXT、DOC、DOCX、MD，最多可上传 300 个文件，每个文件不超过 100MB，PDF 最多 500 页



【阿里巴巴】人工智能技术背景下的设计趋势研究：设计的未来 – 未来的设计【发现报告 fxbaogao.com】.pdf
25.2MB



【数字产业创新研究中心】DIIIC：《大模型行业应用十大典范案例集》【发现报告 fxbaogao.com】.pdf
11.1MB



【火山引擎-IDC】2025年大模型应用落地白皮书：企业AI转型行动指南【发现报告 fxbaogao.com】.pdf
5.5MB



【联通数据智能有限公司】DeepSeek洞察与大模型应用 人工智能技术发展与应用实践【发现报告 fxbaogao.com】.pdf
6.4MB



【沙利文】2024年中国大模型行业应用优秀案例白皮书【发现报告 fxbaogao.com】.pdf
4.3MB



【厦门大学】2025年DeepSeek大模型及其企业应用实践报告-每个人都可以读懂的大模型科普报告（企业篇）【发现报告 fxbaogao.com】.pdf
17.0MB

93%



【智研咨询】2025年deepseek技术全景解析——重塑全球AI生态的中国力量【发现报告 fxbaogao.com】.pdf
14.3MB

49%

✓ 上传2 创建设置3 分段预览4 数据处理

文档解析策略

精准解析

将从文档中提取图片、表格等元素，需要耗费更长的时间

提取内容

☒ 图片元素 ⓘ

☒ 扫描件 (OCR)

☒ 表格元素

内容过滤

[设置过滤内容](#)

未设置任何过滤内容

快速解析

不会对文档提取图像、表格等元素，适用于纯文本

分段策略

自动分段与清洗

自动分段与预处理规则

自定义

自定义分段规则、分段长度及预处理规则

按层级分段

按照文档层级结构分段，将文档转化为有层级信息的树结构

配置存储

平台共享存储

平台预置的默认存储

云搜索服务

使用火山云搜索服务专享资源，数据隔离

自动分段与清洗

文档列表

【阿里巴巴】人工智能技术背景下的设计趋势研究

【数字产业创新研究中心】DIIIR... 处理中

【火山引擎-IDC】2025年大模型... 处理中

【联通数据智能有限公司】Dee... 处理中

【沙利文】2024年中国大模型... 处理中

【厦门大学】2025年DeepSeek... 处理中

【智研咨询】2025年deepseek... 处理中

原始文档预览

< 1 / 75 > - 100% +

阿里云

人工智能技术背景下的设计趋势研究

设计的未来 & 未来的设计

阿里云（北京）科技有限公司

阿里云智能集团研究院 · 阿里云智能集团设计部 · 阿里云智能集团公共事务部

分段预览

14

工具革新

15

趋势一 从数字资产到模型资产，设计要素迎来全面升级

17

趋势二 从单点助力到全流程加速，生成式AI带来效率的大幅提升

19

趋势三 设计更加开放创新，生成式AI让每个想法都能被看见

21

趋势四 从点到面，生成式AI加速设计应用场景的无限扩展

22

能力升级

EE

趋势五 生成式人工智能成为点燃创意火花，将灵感转化为现实的催化剂

35

趋势六 从手工到智能，生成式人工智能加速创意原型的可行性验证

37

趋势七 从设计执行者向决策者转型，设计师能力模型将全面升级

40

流程重塑

44

趋势八 从人机协作到人智协同，生成式人工智能重塑设计流程

46

趋势九 设计师迎来解放双手，深化思考的全新工作模式

48

生态进化

61

趋势十

63

设计生态迎来多元、开放和融合创新的新篇章

2

人工智能×设计趋势研究：设计的未来&未来的设计

报告概览

上一步

下一步

✓

上传

✓

创建设置

✓

分段预览

4

数据处理

服务器处理中

【阿里巴巴】人工智能技术背景下的设计趋势研究：设计的未来 – 未来的设计【发现报告 fxbaogao.com】.pdf 0 Byte	1% (剩余时间6分0秒)
【数字产业创新研究中心】DIIRC：《大模型行业应用十大典型案例集》【发现报告 fxbaogao.com】.pdf 0 Byte	1% (剩余时间6分0秒)
【火山引擎-IDC】2025年大模型应用落地白皮书：企业AI转型行动指南【发现报告 fxbaogao.com】.pdf 0 Byte	1% (剩余时间6分0秒)
【联通数据智能有限公司】DeepSeek洞察与大模型应用 人工智能技术发展与应用实践【发现报告 fxbaogao.com】.pdf 0 Byte	1% (剩余时间6分0秒)
【沙利文】2024年中国大模型行业应用优秀案例白皮书【发现报告 fxbaogao.com】.pdf 0 Byte	1% (剩余时间6分0秒)
【厦门大学】2025年DeepSeek大模型及其企业应用实践报告-每个人都可以读懂的大模型科普报告（企业篇）【发现报告 fxbaogao.com】.pdf 0 Byte	1% (剩余时间6分0秒)
【智研咨询】2025年deepseek技术全景解析——重塑全球AI生态的中国力量【发现报告 fxbaogao.com】.pdf 0 Byte	1% (剩余时间6分0秒)

Q 搜索

文档列表

【阿里巴巴】人工智能技术背景下...

【数字产业创新研究中心】DIIRC...

【火山引擎-IDC】2025年大模型...

【联通数据智能有限公司】DeepS...

【沙利文】2024年中国大模型行业...

【厦门大学】2025年De... 处理中 19%

【智研咨询】2025年deepseek技...


【阿里巴巴】人工智能技术背景下的设计趋势研究：设计的未来 – 未来的设计【发现报告 f...本地自动分段

预览原始文档

12
致谢
13
编纂委员会
14
工具革新
15
趋势一 从数字资产到模型资产，设计要素迎来全面升级
17
趋势二 从单点助力到全流程加速，生成式AI带来效率的大幅提升
19
趋势三 设计更加开放创新，生成式AI让每个想法都能被看见
21
趋势四 从点到面，生成式AI加速设计应用场景的无限扩展
22
能力升级
EE
趋势五 生成式人工智能成为点燃创意火花，将灵感转化为现实的催化剂
35
趋势六 从手工到智能，生成式人工智能加速创意原型的可行性验证
37
趋势七 从设计执行者向决策者转型，设计师能力模型将全面升级
40
流程重塑
44
趋势八 从人机协作到人智协同，生成式人工智能重塑设计流程
46
趋势九 设计师迎来解放双手，深化思考的全新模式
48
生态进化
61
趋势十
63
设计生态迎来多元、开放和融合创新的新篇章
2
人工智能×设计趋势研究：设计的未来&未来的设计
报告概览

将知识库添加给agent

APB





用户MTkwW4

设计一个和大模型有关的项目



个人职场助理

☰ 隐藏运行过程



🔄 已搜索知识库

1.1s

可以设计一个基于大模型的汽车智能化升级项目，以下是具体内容：

项目背景

AI 大模型在汽车行业的应用正日渐广泛，能够处理复杂的数据集并提取相关特征信息，为提升车辆智能化提供了强有力的支持。星途作为奇瑞面向科技中产家庭的中高端品牌，拥有科技向定位，结合 AI 模型技术提升其智能化水平与车主体验是奇瑞的主要需求。

项目目标

1. 推动智能驾驶与智能座舱融合，从单模到多模的生成式人工智能，助力星途在大模型

Recall slice 1

【沙利文】2024年中国大模型行业应用优秀案例白皮书【发现报告 fxbaogao.com】.pdf

大模型应用案例 Score: 0.53

解决方案提供

- 星途作为奇瑞面向科技中产家庭的中高端品牌，拥有科技向定位，因此结合AI模型技术，提升星途智能化水平与车主体验为奇瑞的主要需求。
- 基于讯飞星火认知大模型，科大讯飞与奇瑞联合打造了 Lion AI大模型平台。基于各自优势资源，在汽车智能座舱、智能音效、智能销服、国际多语种、智能驾驶、工业智能及企业数字化等七大领域全面深化合作

案例解析

方案实现效益

...

查看全部

Recall slice 2

【沙利文】2024年中国大模型行业应用优秀案例白皮书【发现报告 fxbaogao.com】.pdf

大模型应用案例 Score: 0.51

汽车行业大模型应用与优秀案例

- AI大模型在汽车行业的应用正日渐广泛，大模型由大规模的神经网络构成，能够处理复杂的数据集并提取相关特征信息。此外，通过大量的数据优化，大模型展现出卓越的学习和泛化能力，从而能够在多个领域应用，在汽车行业也为提升车辆智能化提供了强有力的支持。
- 目前 AI大模型在汽车行业主要应用场景包含自动驾驶、故障预测和虚拟测试及智能座舱等。

Recall slice 3

【沙利文】2024年中国大模型行业应用优秀案例白皮书【发现报告 fxbaogao.com】.pdf

大模型应用案例 Score: 0.50

- AI大模型在高端制造潜在应用诸多，覆盖从产品的研发设计、生产制造、质量管控

可以设计一个基于大模型的汽车智能化升级项目，以下是具体内容：

项目背景

AI 大模型在汽车行业的应用正日渐广泛，能够处理复杂的数据集并提取相关特征信息，为提升车辆智能化提供了强有力的支持。星途作为奇瑞面向科技中产家庭的中高端品牌，拥有科技向定位，结合 AI 模型技术提升其智能化水平与车主体验是奇瑞的主要需求。

项目目标

- 推动智能驾驶与智能座舱融合，从单模到多模的生成式人工智能，助力星途在大模型时代确立超级竞争优势。
- 发力营销服务场景、企业数字化升级、边缘计算和智能分析三大方向，以供应链智能化创新、应用场景体验进阶和高效智能化决策为用户带来极致智能体验，奠定智能汽车大模型赛道新优势。
- 实现创新引领、能源管理、个性化服务、企业数字化、数据价值释放。

项目内容

- 联合科大讯飞，基于讯飞星火认知大模型，打造 Lion AI 大模型平台。
- 基于各自优势资源，在汽车智能座舱、智能音效、智能销服、国际多语种、智能驾驶、工业智能及企业数字化等七大领域全面深化合作。
- 首搭星纪元 ES，将 Lion AI 大模型应用于该车型。
- 让 Lion AI 大模型加持 AI 语音助手，融合智能座舱与智驾能力，并覆盖营销服务场景、企业数字化升级、边缘计算和智能分析。

项目预期效益


- 通过大模型推动智能驾驶与智能座舱融合，实现从单模到多模的生成式人工智能，助力星途在大模型时代确立超级竞争优势。
- 基于大模型，在营销服务场景、企业数字化升级、边缘计算和智能分析三大方向发力，以供应链智能化创新、应用场景体验进阶和高效智能化决策为用户带来极致智能体验，进而奠定智能汽车大模型赛道新优势。
- 首搭星纪元 ES，实现创新引领、能源管理、个性化服务、企业数字化、数据价值释

- 事实性强的任务RAG-LLM组合
 - 法律咨询辅助
 - 法规条款精准检索+专业解释生成
 - 新闻摘要
 - 基于实时信息源
 - 企业知识管理
 - 内部文档检索
- 创造性任务(如写作)
 - 更多考虑纯生成方案
- 实时性要求极高
 - 需要其他结构



人工流程和工作流组件的关系

APB




流程

角色

结构





- 文案创作
- 基于标题、内容、商品做文案

文案专家

调用大语言模型,使用变量和提示词生成回复

变量名	变量值
input	str. v 知识库检索 - o. x
title	str. v 循环 - title
brief	str. v 循环 - brief

视觉理解输入

变量名	变量值
-----	-----

系统提示词

角色: 电商文案撰写专家
你是一个电商文案撰写专家

目标:
根据新闻和商品信息, 撰写适合微博的营销文案

技能:
1. 阅读新闻, 捕捉卖点和热点
2. 根据给出的商品信息, 捕捉卖点
3. 基于新闻和商品创作文案

工作流:
1. 阅读新闻标题{{title}}和新闻内容{{brief}}
2. 分析{{input}}的商品信息
3. 根据新闻和商品综合创作有热点有卖点的适合新浪微博传播和商品转化的文案

系统提示词

角色： 电商文案撰写专家

你是一个电商文案撰写专家

目标：

根据新闻和商品信息，撰写适合微博的营销文案

技能：

1. 阅读新闻，捕捉卖点和热点
2. 根据给出的商品信息，捕捉卖点
3. 基于新闻和商品创作文案

工作流：

1. 阅读新闻标题{{title}}和新闻内容{{brief}}
2. 分析{{input}}的商品信息
3. 根据新闻和商品综合创作有热点有卖点的适合新浪微博传播和商品转化的文案

输出格式：

文本

限制：

- 描述角色在互动过程中需要遵循的限制条件1
- 描述角色在互动过程中需要遵循的限制条件2
- 描述角色在互动过程中需要遵循的限制条件3



输出结果

APB

本次批处理变量

> input {3}

输入

brief: "极目新闻记者陈凌燕佩古拉晋级（视频截图）1月26日，2026澳大利亚网球公开赛女单第四轮，卫冕冠军凯斯以0-2不敌好闺蜜佩古拉，不仅伤心出局，还得去吃下一款“黑暗料理”。凯斯和佩古拉是好朋友，在场外，两人一起..."

input: "{\n \"价格\": \"12\",\n \"分类\": \"食品\",\n \"最近一个月销售量\": \"900\",\n \"毛利率\": \"21%\",\n \"详情\": \"黑暗料理类似产品\",\n \"退货率\": \"15%\",\n \"商品名称\": \"黑暗料理\"\n}"

title: "澳网卫冕冠军遭淘汰出局，还得吃闺蜜指定的“黑暗料理”"

技能调用

输出

output: "# 黑暗料理跨界澳网，你敢挑战吗？\n\n家人们，2026澳网女单第四轮爆大冷门啦！卫冕冠军凯斯0-2不敌好闺蜜佩古拉，惨遭淘汰不说，还得乖乖去吃闺蜜指定的“黑暗料理”。这“黑暗料理”一下子勾起了大家的好奇心！\n\n咱店里就有类似的“黑暗料理”产品，价格只要12元，性价比超高。最近一个月已经卖出了900件，这么多人都在尝鲜，你还不跟上？而且它有着21%的毛利率，品质绝对有保障。虽然“黑暗”，但喜欢挑战新奇口味的宝子可别错过。就算你尝了觉得不合适，15%的退货率也让你没有后顾之忧。想体验和澳网冠军同款“黑暗”美味，就赶紧下单吧！\n\n#澳网 #黑暗料理 #美食尝鲜"

预览

预览

×

黑暗料理跨界澳网，你敢挑战吗？

家人们，2026 澳网女单第四轮爆大冷门啦！卫冕冠军凯斯 0 - 2 不敌好闺蜜佩古拉，惨遭淘汰不说，还得乖乖去吃闺蜜指定的“黑暗料理”。这“黑暗料理”一下子勾起了大家的好奇心！


咱店里就有类似的“黑暗料理”产品，价格只要 12 元，性价比超高。最近一个月已经卖出了 900 件，这么多人都在尝鲜，你还不跟上？而且它有着 21% 的毛利率，品质绝对有保障。虽然“黑暗”，但喜欢挑战新奇口味的宝子可别错过。就算你尝了觉得不合适，15% 的退货率也让你没有后顾之忧。

想体验和澳网冠军同款“黑暗”美味，就赶紧下单吧！

#澳网 #黑暗料理 #美食尝鲜

人工流程和工作流组件的关系

APB






之后的课中有
专门案例


人工流程和工作流组件的关系

APB



另一个工作流

APB



功能：输入一个业务模式，出现多种风格的卡片

APB

社区团购



社区团购

以团长为核心，集采配送的社区消费模式

社区团购



社区团购

以团长为核心，集采配送的社区消费模式

社区团购



社区团购

以团长为核心，集采配送的社区消费模式

社区团购




社区团购

以团长为核心，集采配送的社区消费模式


- 不同格式
 - 视频
 - 图文
 - 音频
- 不同平台
 - 抖音
 - 小红书
 - 公众号
- 类似人的组织结构





人工流程和工作流组件的关系

APB



- Openai 提出的协议
- 核心作用
 - 让大模型调用外部接口
 - 例如:
 - 数据库
 - 天气
 - 通过这种方式就可以把原有的信息和数据放到大模型中进行加工和输出



- Openai 提出的协议
- 核心作用
 - 让大模型调用外部接口
 - 例如:
 - 数据库
 - 天气
 - 通过这种方式就可以把原有的信息和数据放到大模型中进行加工和输出



- 例如：
 - 用户问“我的订单到哪了”
 - 先用function call 做核心查询
 - 通过用户信息查询物流单号，以及物流最新信息
 - 再调用RAG做辅助信息补充
 - 调用“物流问题解决方案”
 - 再根据Prompt生成风格化
 - 生成回答：亲，现在您的物流已经到xxx了，可能存在驿站了，先看下短信通知吧
 - （根据帮助中心第五条建议）



几个技术的另外一种容易理解的方式

APB

- LLM
 - 大学毕业生
 - 很优秀，什么都懂，但没有企业和行业经验
- Prompt
 - 对大学毕业生的岗位要求
 - 告诉了在岗位要怎么说话、怎么办事
 - 懂了岗位要求，但还是没有行业经验



几个技术的另外一种容易理解的方式

APB

- RAG
 - 给了LLM一堆公司和内部的资料
 - LLM了解的公司调理，具体事情该如何处理
 - 有的比较好相当于有了老师，对公司的经验做了完整学习
 - 这个时候相当于道理都懂了，但不能直接动手
- Function call
 - 给了公司系统的进入权限
 - 可以查数据库了，可以直接退订单了
 - 可以真正干活了





- 既然Function call就是解决llm和外部系统的调用
- 那么MCP的价值是什么
- 首先, Function call 和MCP解决的问题是一样的
- 但MCP比function call 有一些优势



- MCP (Model Context Protocol, 模型上下文协议)
- 2024年11月底, Anthropic推出的开放标准
- 主要目标:
 - 解决LLM与外部数据源及工具间无缝集成的需求
 - 让AI可以访问和操作本地和远程数据



- 创建一个通用标准，使AI应用程序的开发和集成变得更加简单和统一
- 简单来说：如果没有统一标准，每个大模型和每个应用都要写接口，意味着叉乘级别的工作量





- 有很多现成的直接可以用
- Github上已经有了500多个 servers

在modelscope已经有3212个了

APB

MCP 服务

MCP体验

搜索MCP服务 (共3212个)

服务类型: Hosted Local

浏览器自动化250

搜索工具454

交流协作工具182

开发者工具950

娱乐与多媒体51

文件系统157

金融175

知识管理与记忆205

位置服务40

文化与艺术30

学术研究166

日程管理32

Fetch网页内容抓取Hosted

@modelcontextprotocol/fetch

该服务器使大型语言模型能够检索和处理网页内容。将HTML转换为markdown格式，以便于更轻松地使用。

@modelcontextprotocol

62.3k

Fetch网页内容抓取Hosted

@modelcontextprotocol/fetch

该服务器使大型语言模型能够检索和处理网页内容。将HTML转换为markdown格式，以便于更轻松地使用。

@modelcontextprotocol

62.3k

高德地图Hosted

@amap/amap-maps

高德地图是一个支持任何MCP协议客户端的服务器，允许用户轻松利用高德地图MCP服务器获取各种基于位置的服务。

@amap

39.0k

高德地图Hosted

@amap/amap-maps

高德地图是一个支持任何MCP协议客户端的服务器，允许用户轻松利用高德地图MCP服务器获取各种基于位置的服务。

@amap

39.0k

必应搜索中文Hosted

@yan5236/bing-cn-mcp-server

必应搜索中文

@yan5236

9.2k

必应搜索中文Hosted

@yan5236/bing-cn-mcp-server

必应搜索中文

@yan5236

9.2k

LeetCode(力扣)Hosted

@jinzcdev/leetcode-mcp-server

MCP 服务器实现 LeetCode API 集成，支持自动化获取编程题库、用户数据和竞赛信息。

@jinzcdev

5.8k

LeetCode(力扣)Hosted

@jinzcdev/leetcode-mcp-server

MCP 服务器实现 LeetCode API 集成，支持自动化获取编程题库、用户数据和竞赛信息。

@jinzcdev

5.8k

支付宝MCPLocal

@alipay/mcp-server-alipay

是支付宝开放平台提供的 MCP Server，让你可以轻松将支付宝开放平台提供的交易创建、查询、退款等能力集成到你的 LLM 应用中，并进一步创建具备支付能...

@alipay

23.3k

支付宝MCPLocal

@alipay/mcp-server-alipay

是支付宝开放平台提供的 MCP Server，让你可以轻松将支付宝开放平台提供的交易创建、查询、退款等能力集成到你的 LLM 应用中，并进一步创建具备支付能...

@alipay

23.3k

12306-MCP车票查询工具Hosted

@Jooook/12306-mcp

服务器提供一个简单的API接口，允许用户搜索12306的车票。

@Jooook

6.4k

12306-MCP车票查询工具Hosted

@Jooook/12306-mcp

服务器提供一个简单的API接口，允许用户搜索12306的车票。

@Jooook

6.4k

无影 AgentBayHosted

@allyun/wuying-agentbay-mcp-server

无影AgentBay是AI 时代的Agent云基础设施， 面向企业、开发者、AI厂商，提供可一键配置的AI Agent任务执行工具和执行环境。您可以通过无影API或AgentBay...

@allyun

7.8k

无影 AgentBayHosted

@allyun/wuying-agentbay-mcp-server

无影AgentBay是AI 时代的Agent云基础设施， 面向企业、开发者、AI厂商，提供可一键配置的AI Agent任务执行工具和执行环境。您可以通过无影API或AgentBay...

@allyun

7.8k

Github的维基百科DeepWikiHosted

@regenrek/mcp-deepwiki

MCP 服务器用于获取 deepwiki.com 的最新知识，并在 Cursor 和其他代码编辑器中使用

@regenrek

607

Github的维基百科DeepWikiHosted

@regenrek/mcp-deepwiki

MCP 服务器用于获取 deepwiki.com 的最新知识，并在 Cursor 和其他代码编辑器中使用

@regenrek

607

飞常准-AviationHosted

@variflight-ai/variflight-mcp

VarFlight航班信息服务的模型上下文协议 (MCP) 服务器实现方案。该服务器提供了多种工具，支持查询航班信息、天气数据及航班舒适度指标。

@variflight-ai

3.0k

飞常准-AviationHosted

@variflight-ai/variflight-mcp

VarFlight航班信息服务的模型上下文协议 (MCP) 服务器实现方案。该服务器提供了多种工具，支持查询航班信息、天气数据及航班舒适度指标。

@variflight-ai

3.0k

OpenMemoryLocal

@mem0ai/OpenMemory

OpenMemory 是您的个人记忆层，适用于大型语言模型 (LLM) ——私有、便捷且开源。您的记忆数据存储在本地，让您完全掌控自己的数据。在构建具有个性化...

@mem0ai

610

OpenMemoryLocal

@mem0ai/OpenMemory

OpenMemory 是您的个人记忆层，适用于大型语言模型 (LLM) ——私有、便捷且开源。您的记忆数据存储在本地，让您完全掌控自己的数据。在构建具有个性化...

@mem0ai

610

微信读书Hosted

@package/mcp-server-weread

一个为微信读书提供MCP (Model Context Protocol) 服务的工具，支持将微信读书的书籍、笔记和划线数据提供给支持MCP的大语言模型客户端，如Claude...

@package

2.3k

微信读书Hosted

@package/mcp-server-weread

一个为微信读书提供MCP (Model Context Protocol) 服务的工具，支持将微信读书的书籍、笔记和划线数据提供给支持MCP的大语言模型客户端，如Claude...

@package

2.3k

析言MCPLocal

@XGenerationLab/xiyan_mcp_server

一种自然语言交互的数据库查询MCP服务。嵌入专用text-to-sql的SOTA模型获得更高的查询精度

@XGenerationLab

5.4k

析言MCPLocal

@XGenerationLab/xiyan_mcp_server

一种自然语言交互的数据库查询MCP服务。嵌入专用text-to-sql的SOTA模型获得更高的查询精度

@XGenerationLab

5.4k

百度地图Hosted

@baidu-maps/mcp

百度地图提供的MCP Server。包含10个符合MCP协议标准的API接口，涵盖逆地理

@baidu-maps/mcp

今天吃什么Hosted

@worryzyy/howtocook-mcp

让 AI 助手变身私人大厨，为你的一日三餐出谋划策！

@worryzyy/howtocook-mcp

Tavily智搜Hosted

@tavily-ai/tavily-mcp

该服务器使AI系统能够与Tavily的搜索和数据提取工具集成，提供实时的网络信息访

@tavily-ai/tavily-mcp

- MCP解决的核心问题就是大模型和外部系统的接口调用
- 让大模型可以驱动其他的产品或者从其他系统中读取数据
- 相比function call, MCP的优势在于统一接口提高了效率
- 同时也出现了大量可以直接使用的服务





流程

角色

结构



Part Three

03

微调的概念和适用场景

模型微调的概念

注意，产品经理仅需做了解

- 大模型微调：
 - 利用特定领域的数据集对已预训练的大模型进行进一步训练的过程
 - 旨在优化模型在特定任务上的性能
 - 使模型能够更好地适应和完成特定领域的任务



- 核心目的：
 - 微调的核心让大模型在特定领域有定制化的能力和表现
 - 通用大模型的主要目的在于“通用”，但在特定领域一定也是需要提升的
 - 通过微调，可以使模型更好地适应特定领域的需求和特征。



- LLM是个全科大学毕业生
 - 什么都懂
 - 但同时什么也不足够专
- 那么，肯定在专业领域上，比不上
 - 医学研究生
 - 建筑研究生
 - 数学研究生



- 领域知识学习
 - 通过引入特定领域的数据集进行微调
 - 大模型可以学习该领域的知识和语言模式
 - 这有助于模型在特定任务上取得更好的性能



- 培养研究生的方法：
 - 给本科生（LLM）大量专业资料
 - 大量专业练习
 - 让ta成为专业领域的人士



微调模型的场景需求

- 为什么要用微调
- 而不是用提示词工程
- 或者RAG来解决问题？



几个原因带来了微调需求

APB

输出准确性

Prompt工程的限制

成本的长期平衡

数据安全



- 很多论文的实验结果，表明微调过的模型比不微调的模型在企业专属数据集的测试当中，准确率会有 10% 左右的提升
- 在商业领域10%会有至关重要的决定性结果



- Prompt+RAG固然能解决一部分问题
- 但是prompt窗口是有长度限制的
- 越长的Prompt，大模型的推理成本越高，因为推理成本是跟Prompt长度的平方正向相关的
- Prompt太长会因超过限制而被截断，进而导致大模型的输出质量打折



- 当业务量小的时候，通用大模型有明显优势
 - 尽管每次使用的token成本高，但没有前置成本
- 但当业务量足够大，累计的tokens额外费用超过了前置成本累计，就是另外一个情况了



- 如果数据是不能传递给第三方大模型服务的
- 那么搭建自己的大模型微调的必要性就更高了
- 通常开源的大模型都是需要用自有数据进行微调，才能够满足业务的需求，这时候也需要对大模型进行微调



蚂蚁阿福铺天盖地的推广-你看到了么


APB





医疗辅助大模型

APB



关键：可以拍照
还可以拍摄诊断报告、体检报告，
皮肤病状态

- 一个好的医生，核心能力就在于“诊断”
- 有了正确的“诊断”，才可能有正确的“处方”和“治疗”
- 所有的检查，都是为了诊断收集更多数据
- 但作为AI医生，本身获取数据的能力是偏弱的
 - 望闻问切的限制
- 所以准确度就是医疗AI的关键



阿福的方式（背后的通义大模型）

APB

数据类别	来源示例	数据特点	应用场景
脱敏电子病历（EMR）	三级医院HIS系统导出	结构化+非结构化混合，含主诉、现病史、检查结果等	症状推理、诊断建议生成
临床诊疗指南	中华医学会、NICE、UpToDate等	权威性强，格式规范，术语标准	指南遵循性判断、治疗推荐
药品说明书	国家药监局公开文件、药品数据库	内容详尽，包含适应症、禁忌、不良反应等	用药安全性审查
医学教材与综述论文	《内科学》《柳叶刀》等	知识体系完整，解释性强	基础医学知识注入

- 第一段：通用医学知识注入
 - 使用涵盖内科、外科、儿科、妇产科等基础学科的广泛医学文本，通过继续预训练（Continued Pre-training）方式更新模型参数
 - 目标是让模型掌握基本医学术语、疾病分类、解剖生理常识等共性知识




- 掩码语言建模 (MLM)
 - 预测被遮蔽的医学术语
- 下一句预测 (NSP)
 - 判断两个句子是否属于同一病例描述
- 实体链接任务
 - 将文本中的疾病名称链接至标准编码



- 第二段：专科专病精调
 - 针对特定科室（如心血管科、肿瘤科）
 - 单一病种（如糖尿病、慢性阻塞性肺病）
 - 使用该领域的高质量病例和专家标注数据进行监督微调
- 指令微调（Instruction Tuning）
 - 响应如“请根据以下症状给出鉴别诊断”之类的临床指令



```
1 {  
2   "instruction": "根据以下主诉和检查结果，提出前三位可能的诊断。",  
3   "input": "患者男性，68岁，吸烟史40年，近3个月咳嗽加重，伴痰中带血丝，胸部CT显示右肺门占位影。",  
4   "output": [  
5     "中央型肺癌（可能性最大）",  
6     "肺结核（需排除）",  
7     "支气管腺瘤（少见但需考虑）"  
8   ]  
9 }
```



五层结构详解

APB

逻辑

角色

任务目标

用户层

UE、UI

产品经理
UI、UE

良好的用户体验

简洁提问

用户需要的答案

驱动动作结果

应用层

专业提示词

专业回答

提示词工程师
(产品经理部分兼任)

1: 提示词结构化便于开发
2: 提示词技巧提高回答确定性可控性

检索增强
RAG
易读知识库
结构化数据

接口调用
MCP
Function call

研发主导，产品辅助

1: 知识库导入、分块、向量化处理，
建索引、检索
2: RAG能力评测

动作驱动

模型层

垂直大模型

大模型厂商、算法工程师

提升模型泛化能力或者垂直能力
准确性、易用性、成本控制

通用大模型

数据层

丰富可靠的数据湖

大模型厂商+大数据提供方+客户

提供数据
构建大模型易读的公、私数据系统

算法算力层

算法

算力

AI科学家、芯片厂商

提升算法算力水平

Part Four


04

总结

1:确认输出
目标

2:初步确认
输入场景

3:设计LLM
处理





流程

角色

结构



- 机械时代
 - 把人工流程，人手工艺，复刻到机器上
 - 提升效率和和精度
- AI时代
 - 把人工流程，人脑工艺，复刻到智能体
 - 提升效率和和精度



- 用Prompt复刻在这个位置上的人
- 他的
 - 人设
 - 能力
 - 工作流程
 - 风格
 -



- 用什么样的结构满足需求
- 内部信息、规则、提升精度、降低幻觉
 - RAG
- 调用结构化数据库，调用接口
 - Function calling、MCP
- 语气调整、提升精度、降低幻觉
 - 微调



大模型
(LLM)

智能体
(Agent)

提示词
(Prompt)

工作流
(Workflow)



RAG

Function
calling

MCP



- 在coze平台上，复刻今天的工作流
- 并制作适合小红书文案的新角色



下节课：案例篇企业内部降本 增效类AI产品核心技术拆解及 复刻

智在必得

Thanks for having you all the way

