

进阶篇

大模型选型

大模型底座选型 和价值管理



上节回顾

- “如果用户下周再来使用我的产品，AI 记得这周发生的事情，会对用户体验产生质的飞跃吗？”
- 如果答案是肯定的，那么长期记忆就是必选项



记忆给 Agent 带来什么

APB

记忆不只是「记住」—— 它带来连续、个性、效率三重价值。



连续性

跨对话延续:上次说的、做的,这次接着来



个性化

基于历史,给出「专属于你」的响应



效率

不用反复交代背景,一句话就懂你要什么

连续、个性、效率 —— 记忆把「一问一答的工具」升级成「懂你的伙伴」。


L3:碎片记忆

L2:概要记忆

L1:核心画像




APB



记忆系统的整体架构:五个环节

APB

一个完整的记忆系统,是一条「写入→存储→检索→更新→遗忘」的流水线。



个性化的四个层次:从浅到深

APB

个性化不只是「叫对名字」—— 它有由浅入深的四个层次。



内容个性化

给 TA 关心的内容

例:推荐爱吃的口味



交互个性化

按 TA 习惯的方式交互

例:老客直接下单,新客多引导



风格个性化

用 TA 喜欢的语气/详略

例:爱简洁的就少说废话



主动性个性化

预判需求,主动服务

例:快没货了主动提醒复购

从「推对内容」到「主动预判」—— 层次越深,用户越离不开,壁垒越强。

壁垒的三个层次:从功能到关系

APB

壁垒有深浅 —— 记忆和个性化,能把你带到最深的那一层。



功能壁垒

「我的功能比你强」

最浅,容易被抄



数据壁垒

「我的数据比你多」

较深,需要时间积累



关系壁垒

「用户离不开我」

最深,记忆+个性化筑成

功能会被抄、数据能被追,但「用户和你的关系」几乎无法复制 —— 这是终极护城河。

CONTENTS

目录

A I · 产 品 · 商 业

01

模型选型的核心逻辑

02

多模态能力的选型

03

Token成本计算和成本节约

Part One

01

模型选型的核心逻辑

你所在公司的同事

APB

听说token成本不低
咱们这个项目多少？

小孙说的对，技术成本
也是成本，要计算控制
的



老板
钱多多

也不低啊，这个成本能
不能控制啊



同事
孙壮壮

每个月大约不到1w

好的我们算算



技术负责人
李福仁

好的



运营负责人
周泉



AI产品经理
小赵

一段对话

APB



你有想过一个问题么？

就算1w的成本，也比客服人力便宜啊
有什么可算的



什么问题？

如果token成本降低意味着什么？

意味着什么

1:是省下来的都是利润
2:如果能有好的控制，就有可能
商业化了

！！





- 小赵啊
- 记住一件事情
- Token成本控制本身就是AI时代每个公司的一大成本关键
- 也是PM高阶能力之一



很多 AI 产品死在「账没算清」

APB

不是功能不行,是成本撑不住、或者选模型压根不匹配场景。



账没算清的下场

- Demo 惊艳,一上量成本爆炸
- 毛利被 token 费吃光
- 老板问「一次多少钱」答不上来
- 被迫砍功能、降体验



算清账之后

- 知道每次调用花多少、赚多少
- 按场景选对模型,不浪费
- 有据可依地降本增效
- 能向老板证明 ROI

AI 产品的生死线,常常不在技术,而在「单位经济模型」是否成立。

模型底座:既是能力天花板,也是成本大头

APB

你的产品再怎么设计,能力上限由模型决定;成本大头也由它产生。



能力天花板

- 模型不会推理,你的 Agent 就不会
- 模型不支持长文本,RAG 就受限
- 模型没有多模态,就看不懂图
- Prompt 再好也超不过模型上限



成本大头

- token 费用通常是最大变动成本
- 调用量一涨,成本线性甚至更快涨
- 自部署则是算力和运维成本
- 直接决定毛利率

选型同时决定了产品的「能力上限」和「成本下限」——没有比这更关键的决策了。

选错模型的四种代价

APB

选型错误的代价,往往在上量之后才暴露 —— 那时候改已经很贵了。



成本失控

选了过强的模型做简单任务 → 白白多花几倍的钱



能力不够

选了太弱的模型 → 复杂场景答不好,体验崩



速度拖累

模型太慢 → 实时对话卡顿,用户流失



迁移痛苦

深度绑定某家 → 涨价/停服时被动,切换成本高

最常见的错不是「选太弱」,而是「无脑选最强」—— 简单任务用顶配,纯属烧钱。

关键认知:选型是商业决策,不是技术选择

APB

很多团队把选型丢给算法,结果只比「谁分高」——这是最大的误区。



只当技术选择

- 只看榜单分数谁高
- 追最新最强的模型
- 不算成本、不看场景
- 「能跑通就行」



当商业决策

- 先看业务场景要什么
- 算清单次成本和收益
- 权衡速度/质量/成本
- 按 ROI 做取舍

「哪个模型最强」是技术问题;「哪个模型最划算」才是产品经理该回答的问题。

选型的三个维度:能力、成本、风险

APB

任何一次选型决策,都要同时看这三个面 —— 缺一个都会翻车。



能力

够不够用

文本能力、多模态、上下文长度、工具调用



成本

花得起吗

单次成本、规模成本、隐性成本



风险

靠谱吗

稳定性、合规、供应商锁定、数据安全

这节课的模块二三讲「能力」,模块四讲「成本」,模块六讲「风险」—— 三维齐备。

- 基于已有产品或业务的链路，进行脑力层人力替代
 - 降低成本
- 基于场景建立新的产品或链路，达成更好效果
 - 提升效益



- 链条路径都需要计算
 - 进行智能化改造带来的成本
 - 单次成本
 - 持续成本
 - 进行智能化改造带来的收益
 - 成本节约
 - 收益提升
- 来计算智能投入的投入产出比



- 脑力劳动价值的两个维度
 - 难度
 - 占用时长
- 难度意味着单位时间的成本
- 占用时长意味着同样难度在一个流程中的时间成本
- 最需要替换的（如果可行）是难度大且时长长的部分



- 我们在1-1中构造的智能简历匹配
- 如何评估其成本价值
- 简化-第一步只考虑简历和JD的AI化匹配
 - 暂不涉及智能自我介绍和面试教练



给出匹配度分析

APB



deepseek-ai/DeepSeek-V3 | 硅基流动

06/12 02:05

根据你的简历和职位要求，我为你做了详细的匹配度分析，并提供优化建议——

你的核心优势（与岗位要求高度匹配部分）

1. 业务战略 & 产品设计能力

- 简历中已充分体现从「战略规划→产品落地」的全链条经验（如爱奇艺、海底捞、芒果TV案例），完全覆盖岗位职责1/2条。
- 优化建议：在项目描述中增加关键词「业务需求拆解」「产品迭代管理」（对应JD第一条），例如：

“为芒果TV设计电商战略时，拆解IP变现需求，规划数字化选品系统，推动技术团队开发落地，首年实现月流水破亿。”

2. 交互设计 & 工具能力

- 岗位明确要求Axure等工具，但简历未直接提及具体交互设计工具。
- 优化建议：在「芒果TV/海底捞」案例中补充交互设计细节，例如：

“输出私域用户运营交互原型及动效规范，协调前端团队实现高转化率界面。”

3. 数据驱动 & 用户研究

- 海底捞私域增长、爱奇艺智能决策系统等案例已体现数据分析能力（匹配JD第5/6条）。
- 优化建议：量化埋点设计和用户研究贡献，例如：

“设计用户行为埋点方案，通过A/B测试优化海底捞小程序转化路径，注册率提升37%。”

4. 创业与0到1经验

- 作为连续创业者和独角兽高管，远超岗位对「创业热情」的要求（JD第2条）。
- 优化建议：在职业概述中直接点明，例如第一段改为：

“连续创业者+独角兽高管，专注从0到1开创新业务，擅长通过数据与产品设计驱动增长。”

需补充的短板（基于岗位偏好）

1. 法律/金融背景 & 海外学历

- JD明确偏好这两点，但简历未提及。如果有相关经验（如服务过金融客户、海外合作项目），建议补充。
- 替代方案：若完全无相关背景，可弱化学历，强调「全英文环境」能力（如国际合作项目、外企客户）。

2. 生产力工具/协同办公领域

- 简历中缺乏直接相关案例，但「数智化体系」和「管理系统」模块可能相关。
- 优化建议：将现有经验向协同场景靠拢，例如：

“为中电建设设计的数字化转型系统，包含协作流程自动化模块，节省跨部门沟通耗时40%。”

其他建议

1. 结构调整：

- 将「代表作」提前至「主要服务客户」上方，用关键案例瞬间吸引注意力。
- 在职业头衔下增加1-2句摘要，直击JD要求的「逻辑能力」「目标导向」（如：“以数据驱动的产品策略专家，擅长在复杂业务中快速定位关键问题”）。

2. 术语优化：

- 在案例中插入JD高频词（如策略设计、用户研究、埋点、项目管理），帮助HR快速匹配。

最终定位建议

你的背景远超该岗位的常规要求，但为避免overqualified印象，建议：

- 在求职信/面试中强调「对开拓新业务的持续热情」（回应JD第2条）；
- 突出「实操能力」而非管理title，避免让企业担心稳定性。

如果需要，我可帮你改写一段简历内容作为示例。

每次使用的
token成本

设计开发测试
的人力成本

训练和数据成本



需要用工具看到token消耗

APB

人设与回复逻辑

##Role:
你是一名专业的求职顾问，擅长优化求职者简历，符合企业招聘的需求
##Insight:

##Statement
1: 为他设计一份符合企业招聘需求的，条理明确的简历
2: 以量化结果为简历核心输出要素
3: 包括项目描述、个人优势、岗位职责、项目体现的核心价值
##Personality
用专业化的，符合互联网公司的表达方式
##Experiment
给出三个不同的版本
##Response
以表格形式呈现

编排

模型设置

> 模型 豆包·1.5·Pro·32k

技能

> 插件 +

> 工作流 +

> 触发器 +

知识 扣子知识库 自动调用

> 文本 +

> 表格 +

> 照片 +

记忆

> 变量 +

> 数据库 ① +

> 长期记忆 关闭

> 文件盒子 ① 关闭

对话体验

> 开场白 ②

> 用户问题建议 开启

> 快捷指令 ①

预览与调试

用户MTkwW4
hi

token计算
你好！请提供具体的职位描述，我会从中提取职位名称、所需工作经验年限和技能等关键要求。之后你可以给我你的简历，我会根据职位要求评估简历的匹配度并提供反馈。
2.7s | 156 Tokens

用户MTkwW4
hi

token计算
您好呀！为了能给您设计出符合企业招聘需求的简历，还请您提供一些关键信息，比如您期望应聘的岗位、过往工作经历（包括工作单位、岗位名称、工作时间、主要工作职责和取得的成果等）、教育背景、掌握的技能以及参与过的项目情况等。另外，若有目标企业的招聘要求，也可以一并告知我。这样我就能精准地为您打造出高质量的简历啦。
5.8s | 283 Tokens

你能帮我修改简历中的项目描述部分吗？

提供一份简历优化的范例可以吗？

简历中应该如何突出个人技能和优势？

查看上下行token

APB

预览与调试

用户MTkwW4

hi

token计算

你好！请提供具体的职位描述，我会从中提取职位名称、所需工作经验年限和技能等关键要求。之后你可以给我你的简历，我会根据职位要求评估简历的匹配度并提供反馈。

2.7s | 156 Tokens

用户MTkwW4

hi

token计算

您好呀！为了能给您设计出符合企业招聘需求的简历，还请您提供一些关键信息，比如您期望应聘的岗位、过往工作经历（包括工作单位、岗位名称、工作时间、主要工作职责和取得的成果等）、教育背景、掌握的技能以及参与过的项目情况等。另外，若有目标企业的招聘要求，也可以一并告知我。这样我就能精准地为您打造出高质量的简历啦。

5.8s | 283 Tokens

你能帮我修改简历中的项目描述部分吗？

提供一份简历优化的范例可以吗？

简历中应该如何突出个人技能和优势？

调试详情

耗时 7822ms | 717 Tokens 成功 一键反馈

Logid : 20250623114920CFBDD83BACBE239EACC

请求发起时间 : 2025-06-23 11... 首次响应耗时 : 2373ms

调用树 火焰图

用户输入 UserInput

调用 LLM 豆包-1.5-Pro-32k

调用 LLM Seed Suggest

节点详情

类型 : 开始

名称 : UserInput

请求发起时间 : 2025-06-...

结束时间 : 2025-06-23 11...

首字符回复时间 : 2025-06-...

状态 : 成功

整体耗时 : 7822ms

首次响应耗时 : 2373ms

Tokens : 717

输入

状态 : 成功

整体耗时 : 7822ms

首次响应耗时 : 2373ms

Tokens : 717

Input Tokens: 557

Output Tokens: 160

采用Deepseek-chat进行价格估算

APB

模型 ⁽¹⁾		deepseek-chat
上下文长度		64K
输出长度 ⁽³⁾		默认 4K, 最大 8K
功能	Json Output	支持
	Function Calling	支持
	对话前继续写 (Beta)	支持
	FIM 补全 (Beta)	支持
标准时段价格 (北京时间 08:30-00:30)	百万tokens输入 (缓存命中) ⁽⁴⁾	0.5元
	百万tokens输入 (缓存未命中)	2元
	百万tokens输出 ⁽⁵⁾	8元
优惠时段价格 ⁽⁶⁾ (北京时间 00:30-08:30)	百万tokens输入 (缓存命中)	0.25元 (5折)
	百万tokens输入 (缓存未命中)	1元 (5折)
	百万tokens输出	4元 (5折)

第一轮粗估原则：
先按照最大成本可能进行估算
不考虑折扣价格
不考虑优惠时段
不考虑缓存命中率 (默认0%命中)

每次使用的token

APB



deepseek-ai/DeepSeek-V3 | 硅基流动

06/12 02:02 | Tokens: 214 ↑96 ↓118

你好！我完全理解你的需求。

请提供以下内容：

1. 职位描述（你想申请的工作的招聘信息）
2. 你的简历（可以是中文或英文，我会根据职位需求提供针对性的优化建议）

收到后，我会：

- 提取职位描述中的核心要求（经验、技能、岗位名称等）
- 分析你的简历匹配度
- 给出具体优化建议（比如突出哪些经历、调整哪些措辞等）

你可以直接粘贴文字或上传文件，我会帮你仔细对照分析！

• 第一次对话：

- 输入：96
- 输出：118



每次使用的token

APB



deepseek-ai/DeepSeek-V3 | 硅基流动

06/12 02:04 | Tokens: 789 ↑484 ↓305

好的，我已经仔细阅读了这份职位描述。以下是关键需求总结：

核心岗位需求分析

1. 岗位名称：业务产品设计师/产品经理（偏向战略+交互+数据驱动型）
2. 核心能力：
 - 业务战略落地：从业务需求→产品设计→开发落地的全流程经验
 - 工具技能：Axure（高优先级）、PPT/Excel（数据分析必备）
 - 背景偏好：法律/金融专业+海外硕士，英语能力强
 - 软技能：逻辑拆解、跨团队沟通、压力承受力
3. 加分项：
 - 生产力工具/协同办公领域经验
 - 从0到1创业项目经历
 - 埋点设计、用户研究经验

下一步：请提供你的简历（可匿名处理关键信息），我会帮你：

1. 对标匹配度，标注现有简历中可突出的亮点
2. 建议弱化或调整的非相关经历
3. 补充关键词（如“数据驱动”“策略设计”等岗位JD高频词）

需要你补充的信息：

- 你是否有法律/金融专业背景或相关经验？
- 是否有海外学习/全英文工作经历？
- 是否有Axure或其他交互设计工具的实际项目案例？

（可直接粘贴文字或描述大致内容，我会逐条分析）

• 第二次对话：

- 输入：484
- 输出：305



每次使用的token

APB



deepseek-ai/DeepSeek-V3 | 硅基流动

06/12 02:05 | Tokens: 2042 ↑ 1229 ↓ 813

根据你的简历和职位要求，我为你做了详细的匹配度分析，并提供优化建议——

你的核心优势（与岗位要求高度匹配部分）

1. 业务战略 & 产品设计能力
 - 简历中已充分体现从「战略规划→产品落地」的全链条经验（如爱奇艺、海底捞、芒果TV案例），完全覆盖岗位职责1/2条。
 - 优化建议：在项目描述中增加关键词如「业务需求拆解」「产品迭代管理」（对应JD第一条），例如：
“为芒果TV设计电商战略时，**拆解IP变现需求**，规划数字化选品系统，推动技术团队开发落地，首年实现月流水破亿。”
2. 交互设计 & 工具能力
 - 岗位明确要求Axure等工具，但简历未直接提及具体交互设计工具。
 - 优化建议：在「芒果TV/海底捞」案例中补充交互设计细节，例如：
“输出私域用户运营**交互原型及动效规范**，协调前端团队实现高转化率界面。”
3. 数据驱动 & 用户研究
 - 海底捞私域增长、爱奇艺智能决策系统等案例已体现数据分析能力（匹配JD第5/6条）。
 - 优化建议：量化埋点设计和用户研究贡献，例如：
“设计**用户行为埋点方案**，通过A/B测试优化海底捞小程序转化路径，注册率提升37%。”
4. 创业与0到1经验
 - 作为连续创业者和独角兽高管，远超岗位对「创业热情」的要求（JD第2条）。
 - 优化建议：在职业概述中直接点明，例如第一段改为：
“**连续创业者+独角兽高管**，专注从**0到1开创新业务**，擅长通过数据与产品设计驱动增长。”

• 第三次对话：

- 输入：1229
- 输出：813



每次使用的token

APB



deepseek-ai/DeepSeek-V3 | 硅基流动

06/12 02:06 | Tokens: 2624 ↑ 1923 ↓ 701

好的，我为你优化了简历核心模块的表述方式。以下是对标JD需求的重写示例，采用「战略+数据+交互」三线贯穿的逻辑框架——

职业概述

数字化产品战略专家 | 连续创业者

- 10年+从0到1业务开拓经验，深度主导生产力工具/企业服务赛道，主导设计数智化系统覆盖决策、营销、生产等六大模块（呼应JD要求1/6条）
- 擅长通过数据驱动产品迭代：设计埋点方案超20项，用户行为分析量级达千万/日（匹配JD第5/7条）
- 法律/金融领域实战经验：为阳光保险、中国银行搭建智能营销系统，渗透率提升60%+（补足专业背景短板）

关键案例优化（直接回应JD）

1. 海底捞 | 私域运营体系设计（生产力工具场景）

- 交互设计：用Axure输出30+页面原型及动效规范，协同开发团队实现小程序获客转化率提升**210%**（强化工具技能）
- 数据驱动：搭建用户分层模型，通过A/B测试优化触点策略，**2年私域用户从50万→2000万**（量化JD第5条）
- 需求拆解：从业务目标逆向拆解为「引流→复购→裂变」三级功能模块，落地期减少跨部门沟通耗时40%（体现JD第7条逻辑能力）

2. 芒果TV | 电商战略从0到1（协同办公关联场景）


- 战略设计：结合IP流量与国潮元素（注：国潮是法律/金融类企业近年高频需求），规划数字化选品系统，首年月流水破亿

• 项目管理：主导10+部门协作，用甘特图管控关键节点，统计计划提前2个月上线（贴合JD第2条）

- 第四次对话：
- 输入：1923
- 输出：701



对话轮次	对话内容	输入Token数量	输出Token数量
1	基本介绍	96	118
2	职位分析	484	305
3	匹配度分析	1229	813
4	简历改写输出	1923	701
总计		3732	1937



总计使用token

APB

对话轮次	对话内容	输入Token数量	输出Token数量
1	基本介绍	96	118
2	职位分析	484	305
3	匹配度分析	1229	813
4	简历改写输出	1923	701
总计		3732	1937
计算公式		$2/1,000,000*3,732$	$8/1,000,000*1,937$
结果		0.007464	0.01596

合计：0.02296元

- 快速进行定性分析
- 决定这个事情从单次成本是否能够做cover
- 如果详细测算，需要进行一定量真实数据测试，计算平均值
- 并留出一定buffer
- 而快速定性分析基本可以按照
 - 翻10倍价格能不能接受进行定性分析
 - 在这个案例中，翻十倍=0.23元/条
 - 从常识上成本依然比人工大幅度低，以此可以视为定性通过



- 单条成本ok，一定有利润么？
- 不一定
- 如果需求量太少，导致单次开发成本无法进行有效摊销，依然是负向收益
- 所以需要测算开发测试的单次人力成本，做综合评估



在上述的案例中

APB

- 做最基础的智能体（基于提示词）
 - 调试开发+前端，约7天
- 假设不考虑
 - 系统集成
 - 多轮对话的复杂功能
 - 知识库构建
 - 微调
 - 后续运维
- 完全采用基础api调用+前端的方式
 - 预估开发成本约20000（人员费用）/21.75（每月工作天数）*7=6436.78元



模型微调成本-参考要素

APB

模型选择

基础模型大小

预训练语料库的范围与深度

微调数据集

数据量

数据处理

微调次数和迭代

训练周期

实验次数

计算资源

GPU、TPU使用数量和时长

存储和贷款费用

技术支持

专家支持

定制开发

- 开发成本（一次性成本）
 - 6500元
- 单次使用成本（token成本）
 - 0.2元以内




- 用相应的服务在市场的公开价格进行价值评估
- 例如：在简历优化方面
 - 人工：一份200-400元
 - 程序化、AI：如果没有单份价格
 - 可以做简单评估
 - 类似一个月平均生成5份简历
 - 则按照最低客单价每份平均价格4元



- 和人工对比
 - 人工成本: 200-400
 - 平均: 300
 - AI token: 0.2元
 - 成本节约: 299.8元
- 和程序化/AI对比
 - 对比价格: 4元
 - AI token: 0.2元
 - 成本节约3.8元



- 开发成本：6500元
- 每条相比AI带来的价格差3.8元
- 意味着需要进行 $6500/3.8$ 次服务才能完成技术成本摊销
- 约1710次使用



- 如果本身是人工
- 每条成本节约299.8元
- 意味着需要进行 $6500/299.8$ 次服务就能完成技术成本摊销
- 约22次



- 核心评估依据在于
 - 单次使用是否大幅度提升效率
 - 如果单次使用和传统方式没有效率提升，则改造无意义
 - 是否有足够的使用量摊销开发成本
 - 如果使用量太小很长时间无法收回成本则也无必要




- 为什么优质提示词能明显提高大模型输出质量
- 但很多场景下并不愿意这样写
 - 能力问题
 - 成本问题
- 如果一个提示词的使用场景只有一次，而收益不足，去撰写结构化提示词有可能成本>收益
- 所以，构建产品，通过多次使用摊薄大模型调试成本是智能体产品最大的价值



大模型选型上的不可能三角

APB



- 作为常规的大模型应用产品
- 一个常见的误区是要研究大模型的极致性能边界
- 事实上绝大多数应用产品都用不到大模型性能边界
- 更多的是在方向上的合理匹配



- 大模型底座是汽车引擎
- 大模型应用产品是利用引擎做的不同的车
- 我们常态
 - 做个卡车：需要引擎输出能力强、维护费用低，但是加速能力弱
 - 做个20w轿车：需要输出平稳均衡，省油，但各项都不突出
 - 做个100w豪华车：需要安静，加速、极速好，但不省油，引擎贵
- 但是
 - 没有谁是要做F-1赛车的，要把性能压到极致的



- 大模型在常规状态的选型逻辑
 - 合规
 - 符合需求
 - 尽量省token费用



- 极致质量追求：
 - 复杂推理、创意写作、代码生成、多步骤任务规划
 - 接受高延迟和高成本
- 可以考虑的选择：
 - 国外：ChatGPT 5 、 Claude Sonnet
 - 国内：Qwen-Max、Deepseek v4pro、Kimi K3、GLM



- 追求极致速度

- 实时语音对话、高频客服
- 牺牲逻辑深度
- 首字延迟 (TTFT) $< 300\text{ms}$, 吞吐量 (TPS) $> 100 \text{ tokens/s}$

- 可以考虑的选择

- 国外: GPT-4o-mini、Llama-8B
- 国内: Qwen-7B、Yi-Lightning、Doubao lite



- 追求极致成本
 - 离线文档分析、日志处理、长文本总结
 - 足够便宜是核心，慢和笨一点可以接受
- 可以考虑的选择
 - Deepseek V4、Qwen-2.5-7B
 - 私有化方案



成本质量
平衡

中文环境
落地特质

产品演进

防止踩坑



- 需要首先考虑合规
 - 必须选择通过国内备案的模型
 - 直接用国外模型封禁和合规风险非常大
- 需要考虑政府、国企的私有化部署问题
- 需要考虑语言问题
 - 例如Llama3 由于中文语料占比很低，会出现中文问英文答 的问题



- 需要考虑一下如下的大模型底座
- 例如
 - 政府应用：九天
 - 国企制造业：华为盘古



成本质量
平衡

中文环境
落地特质

产品演进

防止踩坑



- 根据产品的发展阶段，采用不同的模型使用策略

验证

发展

成熟



- 根据产品的发展阶段，采用不同的模型使用策略

验证

发展

成熟



- 产品和技术验证阶段
- 用什么模型？
 - 用最强的模型
- 这个阶段，如果GPT 5、Opus、Qwen-Max都解决不了
- 那就不用做了
- 意味着这个开发难度高于目前基础模型能力



- 对一件事情做快速定性决策
- 主要逻辑，假设核心资源在不受限的情况下，或者极端受限状态的决策，用以快速形成是否做的定性决策



- 根据产品的发展阶段，采用不同的模型使用策略

验证

发展

成熟



- 技术产品验证完成，已经有用户实际使用
- 需要通过降低token成本的方式获取更大利润



模型路由 (Model Router)

APB

- 80%的用户问题都比较简单
 - 例如“你好”“在么”
 - 不需要用昂贵的模型token
- 做一个分类器
 - 简单问题丢给便宜模型
 - 例如Deepseek、Qwen-Turbo
 - 复杂问题丢给昂贵模型
- 综合可以降低60%-80%成本



- 一个病人，首先到全科医生进行分诊
- 如果病症很轻，去社区医院
 - 便宜的大模型
- 如果病很重，去三甲医院
 - 贵的大模型
- 如果明确病方向，去专科医院
 - 垂类大模型



- 根据产品的发展阶段，采用不同的模型使用策略

验证

发展

成熟



- 有了足够多高质量用户数据
- 就可以用用户数据微调一个开源小模型
 - 可以考虑7B或者14B参数
- 这样就可以得到一个在特定任务表现较好，同时成本只有1/100的私有模型




成本质量
平衡

中文环境
落地特质

产品演进

防止踩坑



- 不要迷信榜单
 - HuggingFace 上的 OpenCompass 或 LMSYS 榜单仅供参考
 - 模型会针对榜单数据做“刷题”
- 首先不一定榜单低的不能满足业务，也不一定榜单高的一定适合场景
- 简历自己的业务评测数据集，用真实业务数据去测试



- Context Window陷阱
 - 很多模型宣称支持 128k 甚至 1M 上下文
 - 但实际上放到中间的内容很容易被遗忘 (Lost in the Middle 现象)
 - 所以如果有比较长的RAG, 需要实测



成本质量
平衡

中文环境
落地特质

产品演进

防止踩坑



Part Two

02

多模态能力的选型

- 文字模型
- 多模态
 - 多模态理解
 - 多模态生成
 - TTS合成
 - ASR识别



文本能力的六个维度

APB

别笼统说「这个模型强」——拆成六个维度,才知道强在哪、够不够用。



推理能力

多步逻辑、数学、复杂判断



长文本

能吃多长的上下文,长了会不会失焦



指令遵循

让它干什么就干什么,不自作主张



工具调用

能不能准确地调 API、传对参数



中文能力

中文理解和表达是否地道



生成质量

文笔、结构、风格可控性

对 Agent 类产品,「指令遵循」和「工具调用」往往比「推理能力」更影响成败。

不同产品,该看重不同能力

APB

能力没有绝对好坏,只有「匹配不匹配你的场景」。

产品类型	最看重的能力	可以妥协的
客服问答	指令遵循、中文、速度	复杂推理
Agent 工作流	工具调用、指令遵循	文笔
长文档分析	长文本、推理	速度
内容创作	生成质量、风格控制	工具调用
代码助手	代码能力、长文本	中文表达

先写清「我最看重哪两三项能力」—— 这比看综合排行榜有用得多。

正确姿势:用你自己的评估集选型

APB

第七节建的 Eval,正是选型最有力的武器 —— 拿同一套题考所有候选模型。



① 用你的评估集

第七节做的那套评估集,直接复用



② 同题考多模型

把候选模型都跑一遍同样的题



③ 同标准打分

用同一套评分方法,横向对比



④ 结合成本决策

质量分 + 单次成本,一起看

第七节的 Eval 在这里第二次发挥威力 —— 它既是质量守门员,也是选型裁判。

看懂模型规格表:PM 该关注的几个数

APB

模型文档里一堆参数,PM 真正要看懂的是这几个。

	上下文长度	一次能处理多少 token —— 决定 RAG 能塞多少、能读多长文档
	延迟 / 首字时间	多久出第一个字 —— 直接影响对话体验
	吞吐 / 并发	每秒能出多少字、能扛多少并发 —— 影响高峰能力
	定价	输入/输出每千 token 各多少钱 —— 算账的基础

参数量不用太关心(不同架构不可比),但上下文、延迟、定价必须门儿清。

上下文长度:不是越长越好

APB

长上下文很诱人,但用起来有代价 —— 这是常见的认知盲区。



长上下文的好处

- 能塞更多 RAG 检索结果
- 能读整份长文档
- 能保留更长对话历史
- 减少切分和摘要的麻烦



长上下文的代价

- 塞得越多,单次成本越高
- 可能「中间失焦」,漏掉中段信息
- 延迟变长,响应变慢
- 往往并不需要那么长

别为「用得上的 10%」买单 —— 按实际需要的上下文长度选,能省不少钱。

大模型 vs 小模型:不是越大越好

APB

同一家的旗舰和轻量版,能力差几成,价格可能差十倍。



旗舰大模型

- 复杂推理、疑难场景强
- 价格高、速度相对慢
- 适合:复杂任务、低频高价值



轻量小模型

- 简单任务表现足够好
- 便宜得多、快得多
- 适合:高频简单任务、实时场景



关键洞察:大部分实际请求都是简单的 —— 用旗舰模型接所有请求,等于用跑车送外卖。

这个洞察引出模块五的核心策略:分层路由 —— 简单走小的,复杂走大的。

能力评估的完整流程

APB



① 明确要求

写清最看重的 2-3 项能力和底线



② 圈候选

参考榜单和口碑,圈 3-5 个候选



③ 备评估集

用你的业务评估集(第七节)



④ 实测对比

同题同标准,跑出质量分



⑤ 结合成本

质量分 + 单次成本 → 综合决策

多模态四大块

APB

「多模态」不是一个能力,是四类完全不同的能力 —— 选型时要分开评估。



多模态理解

看懂图/视频/文档

输入是图,输出是文字



多模态生成

生成图片/视频

输入是文字,输出是图



TTS 语音合成

文字变语音

输入是文字,输出是音频



ASR 语音识别

语音变文字

输入是音频,输出是文字

四块能力常由不同模型提供、各自计价 —— 千万别当成「一个多模态模型全包」。

为什么 PM 必须懂多模态选型

APB

多模态是产品差异化的主战场,也是成本最容易失控的地方。



体验差异化

能看图、能对话,体验直接上一个台阶



成本结构不同

图片、音频的计价方式和文本完全不一样



质量差异大

不同厂商在各模态上强弱悬殊,不能一概而论



合规风险高

生成内容的版权、声音克隆的授权,都是雷区

多模态用对了是加分项,用错了是成本黑洞和合规隐患 —— 所以要一块块看清楚。

多模态理解:让 AI「看懂」图片和文档

APB

输入图片/视频/文档,输出文字理解 —— 这是最常用的多模态能力。



OCR 文字识别

从图里提取文字

场景:识别小票、标签、截图



图表理解

读懂图表数据和趋势

场景:分析报表、数据图



图像内容理解

理解画面里有什么

场景:识别商品、判断品相



视频理解

理解视频内容和时序

场景:分析短视频、监控

同是「看图」,OCR、读图表、认商品是不同难度 —— 选型要按你的具体任务测。

多模态理解:选型看什么

APB

评估视觉理解能力时,这几点最影响实际效果。



识别准确度

能不能准确认出关键信息(尤其中文小字)



图片规格支持

支持多大分辨率、什么格式、单次几张



中文 OCR

中文识别往往比英文弱,必须单独测



计价方式

按图片数、还是按分辨率折算 token

务必用你自己的真实图片测 —— 用户随手拍的糊图,和演示用的高清图天差地别。

多模态理解的成本特点:一张图 = 很多 token

APB

这是最容易被低估的成本项 —— 图片会被折算成大量 token。



关键认知:图片不是「一次调用一块钱」那么简单

多数厂商会把图片按分辨率折算成 token 计费 —— 一张高清图可能相当于上千 token,比一大段文字还贵。



控制分辨率

按需压缩图片,别传原图 —— 能省很多



限制张数

一次对话限制上传图片数量



按需启用

只在真需要看图时才走多模态模型

上线前一定实测「一张典型图片折算多少 token」—— 这个数会显著改变你的成本模型。

多模态生成:让 AI「画图」和「拍片」

APB

输入文字或图,输出图片或视频 —— 内容生产场景的核心能力。



文生图

文字描述 → 生成图片

场景:营销素材、配图、概念图



图生图

图 + 描述 → 新图

场景:换背景、改风格、扩图



文生视频

文字 → 短视频

场景:短视频素材、动态展示



图像编辑

局部修改、消除、替换

场景:修图、去水印、换元素

生成类能力最适合「内容生产提效」场景 —— 但对准确性要求高的场景要谨慎。

多模态生成:选型看什么

APB

生成类模型的评估维度,和理解类完全不同。



画面质量

出图好不好看、细节到不到位



指令还原度

有没有按描述画,细节对不对



中文理解

中文提示词能不能准确理解



文字渲染

图里的中文字能不能写对(常见弱项)



生成速度

一张图几秒还是几十秒



一致性

多次生成能否保持风格/角色一致

中文场景特别注意两点:中文提示词理解、图中中文字渲染 —— 这两项差异极大。

TTS 文本转语音:让 AI「开口说话」

APB

把文字变成语音 —— 语音客服、有声内容、无障碍场景的基础能力。



语音客服

电话或语音助手里播报回答



有声内容

文章、小说转成音频



语音助手

车载、智能音箱等免手场景



无障碍

为视障用户朗读内容

TTS 的价值在于「解放眼睛和手」—— 凡是用户不方便看屏幕的场景,它就有用武之地。

TTS 选型:六个评估维度

APB

语音的「像不像人」,决定了体验是加分还是出戏。



自然度

听起来像真人还是机器腔



音色选择

有多少音色可选、能不能定制



情感表达

能不能有语气起伏、情绪



流式延迟

第一个字多久出来(实时对话关键)



多语言方言

支持哪些语言、有没有方言



可控性

语速、停顿、多音字能否调整

实时对话场景,「流式延迟」比「音质完美」更重要——卡三秒再好听也没用。

ASR 语音识别:让 AI「听懂人话」

APB

把语音转成文字 —— 语音输入、会议记录、通话质检的基础。



语音输入

用户说话代替打字,开车、走路时好用



会议/通话记录

把录音转成文字纪要



客服质检

把通话转文字后做质量分析



内容字幕

为视频自动生成字幕

ASR 是很多语音产品的入口 —— 它识别错了,后面的模型再强也是白搭。

ASR 选型:六个评估维度

APB

实验室准确率和真实环境准确率,常常差很远。



识别准确率

标准普通话下的基础准确率



方言口音

带口音、方言时还准不准



噪声鲁棒性

嘈杂环境下的表现



实时性

流式识别延迟、边说边出字



垂类词表

能否加入行业术语、商品名



多语言

支持哪些语言、能否混说

「垂类词表」是被低估的功能 —— 把你的商品名加进去,识别准确率能明显提升。

← 返回

GPT、DeepSeekV4 已结束

AI 应用产品经理 · 工具协议 · AI 应用产品经理知识库 · 音源: 标签页音频

已学习 2:20:42

▶ 课程已结束

□ 已结束

查看总结

知识地图

大模型相关技术知识

- ☐ RAG x0
- ☒ MCP x1
- ☒ Agent x4
- ☐ Function Calling x0
- ☐ Prompt Engineering x0
- ☐ Embedding x0
- ☐ Vector Database x0
- ☐ Fine-tuning x0
- ☐ LLM x0
- ☒ Token x12
- ☐ Context Window x0
- ☒ Retrieval x2
- ☐ Evaluation x0
- ☐ Hallucination x0
- ☐ Guardrails x0
- ☒ Multi-modal x7
- ☐ Tool Use x0
- ☐ Intent Recognition x0
- ☐ Structured Output x0

实时转写

听悟实时: 麦克风 → WebSocket → 转写; 命中术语自动高亮。

听悟模式: 开始同步转写时会请求音频采集权限; Codex 内置浏览器可能无法授权麦克风或标签页音频。请用 Chrome/Edge 打开当前 localhost 地址进行真实同步。

已转写 272 段

正在查看历史

理2.8万, 12.8万个头很几乎相当的时候, 就完全不一样。

06:19 转写

然后这里面还去加了一个混合处理, 混合机制, 就是这个CIC和HCA. 它这个CSA叫做压缩
稀疏注意力。

06:38 转写

它是通过deep si ck的 **稀疏注意力** 的这个技术, 就是DSA, 也就是和它的这个 **MOE** 有点类似, 它仅关注上下文最相关的 **token** 集群。有一些东西, 其实他发现和他的整体的上的上下文的关系没有这么的高。比如说有些偏于废话水分, 他没有这么的高, 对吧? 然后减极大的减少了他的计算的冗余度。

06:48 转写

然后另外一个就是这个叫做ACA, 就是重压缩 **注意力**, 然后把很多的跨 **token** 级的KV条目去做压缩了。

07:08 转写

然后使得整体的KV的缓的缓冲体积会变小。最后的结果, 我不知道你们能听不能听不懂, 反正最后的结果是这样子的, 百万级 **token** 级别的长文本, deep sake v4 pro的推理的这个flops是V3.2的, 27%, 这是它非常牛的一件事儿。

07:17 转写

就是它不只是通过给补贴的方法, 我认为deep seek现在的技术思路方向已经非常明确了。

回到最新转写

知识对话

AI 面板

笔记

在 AI 产品中的作用
适合文档理解、图像标注与多媒体客服等场景。

典型应用场景

[票据识别](#) [图纸问答](#) [视频摘要](#)

关联知识点

[LLM](#) [Embedding](#)

历史课程关联

暂无历史关联 (可在后续接入课程记忆库)。

本节课中出现片段

20:01

好, 然后成本处理解决, 然后去做什么, 做性能提升, 他性能提升做了一些什么事。这是我给大家看到测评的状态。另外一个deep seat在V4的预训练中做了 **多模态** 融合。大家看到这个我写这个。对, 就是今天就开始在 **多模态** 上其实去做灰度了, 对不对?

20:27

然后它是一个原生 **多模态** 架构的deep seek v4是原生 **多模态** 架构。我其实今天他灰度出来, 我其实是既有点儿感觉好, 又觉得有一点卡唱。然后他晚一天灰度我就成预言家, 他的预训练是做的是 **多模态** 认知融合。

20:43

他是一个和Jimmy一样的原生 **多模态** 架构, 很厉害。它通过原生 **多模态** 架构的话, 它能做到跨模态推理的一致性。

追问 AI 当前围绕「Multi-modal」

关于「Multi-modal」继续追问...

发送

听悟实时：麦克风 → WebSocket → 转写；命中术语自动高亮。

听悟模式：开始同步转写时会请求音频采集权限；Codex 内置浏览器可能无法授权麦克风或标签页音频，请用 Chrome/Edge 打开当前 localhost 地址进行真实同步。

已转写 272 段

正在查看历史

理2.8万，12.8万个头很几乎相当的时候，就完全不一样。

06:19 转写

然后这里面还去加了一个混合处理，混合机制，就是这个CIC和HCA. 它这个CSA叫做压缩
稀疏注意力。

06:38 转写

它是通过deep si ck的**稀疏注意力**的这个技术，就是DSA，也就是和它的这个**MOE**有点类似，它仅关注上下文最相关的**token** 集群。有一些东西，其实他发现和他的整体的上的上下文的关系没有这么的高。比如说有些偏于废话水分，他没有这么的高，对吧？然后减极大的减少了他的计算的冗余度。

06:48 转写

然后另外一个是这个叫做ACA，就是重压缩**注意力**，然后把很多的跨**token** 级的KV条目去做压缩了。

07:08 转写

然后使得整体的KV的缓的缓冲体积会变小。最后的结果，我不知道你们能听不能听不懂，反正最后的结果是这样子的，百万级**token** 级别的长文本，deep sake v4 pro的推理的这个flops是V3.2的，27%，这是它非常牛的一件事儿。

07:17 转写

就是它不只是通过给补贴的方法，我认为deep sick现在的技术思路方向已经非常明确了。

回到最新转写

知识对话

AI 面板

笔记

已发送知识点卡片

稀疏注意力 命中 ×0

通过减少注意力计算范围来降低长上下文成本的技术。

术语映射

稀疏注意力 → Sparse Attention / 稀疏 Attention / 稀疏化注意力

详细解释

稀疏注意力不会让每个 Token 都关注全部上下文，而是用局部、窗口或模式化策略保留关键依赖。它常用于提升长文本推理效率和可扩展性。

在 AI 产品中的作用

帮助长文档、代码库和知识库产品在成本与效果之间做更现实的方案取舍。

典型应用场景

百万 Token 文档分析

代码库问答

长会议复盘

关联知识点

注意力机制

Context Window

成本优化

推理服务

🕒 历史课程关联

暂无历史关联（可在后续接入课程记忆库）。

本节课中出现片段

06:19

然后这里面还去加了一个混合处理，混合机制，就是这个CIC和HCA. 它这个CSA叫做压缩**稀疏注意力**。

🔍 追问 AI 当前围绕「稀疏注意力」

关于「稀疏注意力」继续追问...

发送

能用在哪儿

稀疏注意力（Sparse Attention）主要用于需要处理长文本或高计算效率的场景，例如：

- 长文档理解**：如法律合同、学术论文，只关注关键段落，忽略无关内容。
- 对话系统**：在长对话中聚焦当前主题，减少历史噪音。
- 代码生成**：只关注相关函数或变量，避免全局计算。
- 视频/图像处理**：对高分辨率数据，仅处理局部区域或关键帧。

简单说，它适合“信息密度低、上下文长”的任务，能省算力、提速度。

🔍 追问 AI 当前围绕「稀疏注意力」

关于「稀疏注意力」继续追问...

发送

我们做的ASR评测

APB

#	模型	CER_NORM	CER_RAW	类型 / 备注	报告
1	FireRed Stream-VAD + FireRedASR2-AED 最优	12.24%	16.73%	离线, VAD 切分后逐段推理	2026-07-13
2	FireRedASR-AED-L	13.01%	17.66%	离线 1.1B, 20s 固定切分	2026-07-09
3	Paraformer-zh 课伴生产基线	14.14%	23.10%	FunASR 默认中文离线模型 + ct-punc	2026-07-09
4	Paraformer-large (历史评测)	14.39%	23.43%	FunASR 220M + ct-punc	2026-07-09
5	Paraformer-large (soxr 重跑)	14.57%	23.56%	同上, 核实重采样一致性后重跑	2026-07-15
6	paraformer_small 插件 A/B 变体	14.77%	19.22%	sherpa-onnx 离线 Paraformer, 20s 切分	2026-07-16
7	SenseVoiceSmall	14.85%	25.62%	离线多任务模型 (自带 ITN/标点)	2026-07-09
8	Zipformer fp16-2025-06-30 (stream / chunk320, soxr)	16.58%	20.82%	流式 transducer	2026-07-10
9	Zipformer int8-2025-06-30 (whole-stream, soxr)	16.61%	20.86%	流式 transducer 服务端候选	2026-07-10 / 07-15
10	zipformer_wenetspeech 插件默认	19.05%	22.90%	sherpa-onnx 离线 transducer, 20s 切分	2026-07-16
11	听悟离线 (课伴 Web 同款)	19.73%	26.25%	阿里云云端 ASR	2026-07-09
12	听悟流式 (课伴 Web 同款)	21.55%	27.81%	阿里云云端 ASR	2026-07-09
13	Zipformer int8 (线性插值重采样) 方法有缺陷	21.69%	25.82%	与 #9 同一模型, 仅重采样方法不同	2026-07-10
14	Dolphin CTC base int8	26.51%	32.04%	多语言离线 CTC, 20s 切分	2026-07-15
15	TeleSpeech CTC int8	46.66%	49.84%	中文离线 CTC, 20s 切分	2026-07-15

- 这个项目的特殊之处在于成本
- ASR是成本比较高的
- 通义的价格

新版接口商用价格

模块	功能	是否可选	标准价格 (元/小时)
ASR	实时会议转写 (送说话人分离)	二选一即可	0.6
	音视频文件转写 (送说话人分离、自动语种识别)		0.6
大模型	包含：章节速览、全文摘要、发言总结、问答回顾、思维导图、待办事项、关键词、重点内容、口语书面化、自定义 Prompt	分别可选，各项能力按照处理的音视频时长，独立计费 使用多个能力和多个 Prompt 时，叠加计费（如使用关键词和章节速览，计费为 $0.064+0.064=0.128$ 元/小时）	0.064
	包含：服务质检、对话内容提取	可选，按照处理的音视频时长计费	0.13
多模态	多模态（视频 PPT 提取+PPT 摘要）	可选	0.64
翻译	实时翻译	可选	4
	离线翻译	可选	0.5

而讯飞，最便宜一小时3.5!!!

APB

套餐	体验包	新用户礼包	套餐一	套餐二	套餐三	套餐四
时长量	5小时	最高50小时	10小时	200小时	1000小时	3000小时
有效期	30天	一年	一年	一年	一年	一年
单价 (元/小时)	免费	免费	¥9.9/小时 ¥8.8/小时	¥5.9/小时 ¥4.9/小时	¥4.9/小时 ¥3.9/小时	¥4.9/小时 ¥3.5/小时
总价 (元)	免费	免费	¥99 ¥88	¥1180 ¥980	¥4900 ¥3900	¥14700 ¥10500
使用服务	立即领取	立即领取	立即购买	立即购买	立即购买	立即购买



ASR 实测:一定要用真实录音

APB

厂商给的准确率是理想条件下的 —— 你要用用户的真实环境测。



真实录音

用用户实际环境录的音频测,不用标准朗读



加入噪声

测试背景音乐、马路、多人说话等场景



覆盖口音

找不同地域的人录音测试



业务词汇

重点测商品名、专有名词识别情况

ASR 的成本通常按音频时长算,相对便宜 —— 但准确率不够会毁掉整个体验。

四类多模态能力:选型速查表

APB

一张表看清四类能力的关键评估点和计价方式。

能力	关键评估点	典型计价	主要风险
理解	准确度、中文OCR、图片规格	按图折算 token	成本被低估
生成	质量、指令还原、中文字	按张/按秒	版权合规
TTS	自然度、流式延迟、音色	按字符/时长	克隆授权
ASR	准确率、口音、噪声、词表	按音频时长	真实场景掉准

四类能力各自独立选型、各自计价 —— 这张表是你做多模态选型的起点。

多模态不一定要一个模型全包

APB

常见做法是「专项专用」——每块能力选各自最合适的服务。



一体化多模态模型

- 一个模型处理文本+图像
- 集成简单、上下文统一
- 但某些模态可能不是最优
- 价格通常按旗舰算



专项组合方案

- ASR 用专门的语音服务
- TTS 用专门的合成服务
- 图像理解用视觉模型
- 各选最优,成本可优化

起步可用一体化图省事;量大了再拆成专项组合,通常能明显降本增效。

Part Three

03

Token成本计算和成本节约

token 到底是什么

APB

token 是大模型处理文本的最小单位,也是计费单位 —— 算账从这里开始。



token $\neq$ 字,也 $\neq$ 词

模型把文本切成一个个小片段(token)来处理。英文里一个 token 大约是 3/4 个单词;中文里通常 1 个汉字约等于 1~2 个 token。



中文更费 token

同样意思,中文消耗的 token 通常比英文多



输入输出都算钱

你发过去的算输入,模型回复的算输出



两者单价不同

输出 token 通常比输入贵好几倍

记住这三件事:中文更费、输入输出都算钱、输出更贵 —— 后面所有算账都基于它们。

估算方式：工具的功能

APB

试运行

23s | 3242 Tokens 查看日志

用户MTkwW4

你好

智能客服

你好呀😊！我还记得你喜欢酸、甜、辣口味的零食呢，有什么想聊的吗？



来源

Token

输出

633 Tokens

输入

2609 Tokens

总计

3242 Tokens

ceshi 10ms

- 长期记忆检索 377ms
- 记忆召回节点 7.28s
 - 豆包·1.8·深度思考 7.20s
- 查询会话历史 6ms
- 用户偏好提取 1.25s
 - 豆包·1.8·深度思考 1.16s

总积分

16.23

模型

豆包·1.8·深度思考

6.23

计费项

刊例价

用量

积分

豆包·1.8·深度思考

0.8 积分/千Tokens输入 - 输入[0,32]且输出(0.2,+∞)

1.55

1.24

豆包·1.8·深度思考

8 积分/千Tokens输出 - 输入[0,32]且输出(0.2,+∞)

0.48

3.84

豆包·1.8·深度思考

0.8 积分/千Tokens输入 - 输入[0,32]且输出[0,0.2]

1.059

0.85

豆包·1.8·深度思考

2 积分/千Tokens输出 - 输入[0,32]且输出[0,0.2]

0.153

0.31

记忆库

记忆库检索

10.00

计费项

刊例价

用量

积分

记忆检索

10 积分/次

1

10.00

成本大头往往不是用户的话

APB

系统 Prompt 和 RAG 内容,才是真正吃 token 的地方。



想降本?先去看系统 Prompt 有没有冗余、RAG 是不是塞多了 —— 那才是大头。

单次调用成本:完整算式

APB

把 token 数换算成钱 —— 这是本节最重要的一个公式。

$$\text{单次成本} = \text{输入 token} \div 1000 \times \text{输入单价} + \text{输出 token} \div 1000 \times \text{输出单价}$$

(多数厂商按「每 1000 token」定价,输入和输出分开计价)



两类 token 分开

输入和输出必须分开算,单价不同



单价看清单位

注意是每 1000 还是每 100 万 token



别忘了汇率

海外模型按美元计价,要换算

这个公式背下来 —— 面试、汇报、做决策时,你随时要能算出「一次多少钱」。

实算:零食客服一次咨询花多少钱

APB

用刚才拆出的 token 数,代入公式算一遍(单价为示意值)。

输入 token	2,120 token
输出 token	150 token
假设输入单价	0.004 元 / 1000 token
假设输出单价	0.012 元 / 1000 token
输入成本	$2,120 \div 1000 \times 0.004 \approx 0.0085$ 元
输出成本	$150 \div 1000 \times 0.012 = 0.0018$ 元
单次总成本	≈ 0.010 元(约一分钱)

一次咨询约一分钱 —— 单看很便宜,但乘以日均 8000 次咨询,就是另一回事了。

多模态怎么计价:和文本完全不同

APB

加了多模态,成本模型要单独算 —— 这是最容易漏的一块。

模态	典型计价方式	成本量级感受
文本	按输入/输出 token	最便宜,一次几厘到几分
图像理解	按分辨率折算 token	一张图可能顶上千 token
图像生成	按张计价	一张图通常远高于一次文本对话
视频生成	按秒计价	最贵,几秒视频可能是几百次文本对话
TTS	按字符数或音频时长	较便宜,但长音频会累积
ASR	按音频时长	较便宜,按分钟计

视频生成是成本量级最高的 —— 引入前一定先算清「一条视频等于多少次对话」。

哪些因素在推高你的单次成本

APB



系统 Prompt 太长

写得啰嗦、few-shot 太多 → 每次都在为冗余付费



RAG 塞太多

TopK 设太大、切片太长 → 输入 token 暴涨



对话历史太长

不做裁剪 → 轮次越多越贵



重试与多轮

失败重试、多次澄清 → 一个任务调用多次

注意「重试」这一项 —— 它最隐蔽: 体验没变, 成本却悄悄翻了倍。

六个实用的降本手段

APB

在不牺牲体验的前提下,这些方法能显著压低单次成本。



模型分层

简单任务走小模型



缓存复用

高频相同问题直接复用答案



精简 Prompt

删冗余、压缩 few-shot



裁剪上下文

限制 RAG TopK、摘要历史



批处理

非实时任务批量提交,常有折扣



控制多模态

压缩图片、限制张数、按需启用

性价比最高的两招:模型分层 + 缓存 —— 通常能砍掉一半以上的成本。

更要算收益:三种收益模型

APB



替代人工

省下的人力成本

适用:客服、审核、录入类



提升转化

多赚的销售额

适用:导购、推荐、营销类



节省时间

省下的时间 $\times$ 时薪

适用:效率工具、内部提效

选一条最贴合你业务的路径来算 —— 算不出钱的 AI 功能,很难在预算会上活下来。

收益算法一:替代人工怎么折算

APB

最直观的一种 —— AI 处理一次,相当于省了人工多少钱。

单次收益 = 人工处理一次的成本 × AI 独立解决的概率

(没解决的会转人工,那部分不算收益)

人工成本

客服月薪 + 五险一金 ÷ 月处理量 → 单次人工成本

示例假设

一次人工咨询成本约 2 元

AI 解决率

第六节 PRD 定的目标:70%

单次收益

2 元 × 70% = 1.4 元

注意乘上「解决率」—— 这是很多人算 ROI 时最容易忽略的折扣项。

收益算法二:提升转化怎么折算

APB

适合导购、推荐类场景 —— AI 让用户多买了多少。

$$\text{单次收益} = \text{客单价} \times \text{毛利率} \times \text{转化率提升幅度}$$

(要用 A/B 实验测出真实的转化提升,不能拍脑袋)

客单价

假设 80 元

毛利率

假设 30%

转化提升

A/B 实验测得提升 2 个百分点

单次收益

$80 \times 30\% \times 2\% = 0.48 \text{ 元}$

转化提升必须靠 A/B 实验拿到

单次 ROI:把成本和收益放在一起

APB

这是判断一个 AI 功能「值不值得做」最直接的指标。

$$\text{单次 ROI} = \text{单次收益} \div \text{单次成本}$$

ROI > 1 才算划算;ROI 越高,这个功能的经济性越好

单次成本

≈ 0.010 元

单次收益(替代人工)

≈ 1.40 元

单次 ROI

$1.40 \div 0.010 = 140$ 倍

140 倍看起来很夸张 —— 但这正是客服类 AI 值得做的原因:人工太贵,AI 太便宜。

别被高 ROI 骗了:四个隐藏成本

APB

只算 token 费的 ROI 是「毛 ROI」—— 真实账要把这些也算进去。



研发与运维

开发、部署、监控的人力投入



数据与标注

知识库维护、评估集标注(第七节)



人工兜底

没解决的 30% 仍需人工,成本还在



错误代价

答错导致的投诉、赔付、品牌损失

汇报时讲「毛 ROI」很好看,但做决策要用「含隐藏成本的净 ROI」—— 别自己骗自己。

从单次到规模:算出月度账

APB

单次算清了, 乘上量级, 就是老板真正关心的数字。

日均咨询量	8,000 次
月咨询量	$8,000 \times 30 = 240,000$ 次
月成本	$240,000 \times 0.010$ 元 $\approx 2,400$ 元
月收益	$240,000 \times 1.40$ 元 $\approx 336,000$ 元
月净收益	$336,000 - 2,400 \approx 333,600$ 元

这就是你该带去预算会的那张表: 月成本几千, 月节省几十万 —— 决策一目了然。

做的不错啊，周泉，你
怎么看

小孙、老李，你们的意
见呢？



老板，我们计算了一下，
目前咱们平均每天咨询
量8000，AI做到了70%
替代，单次沟通成本大
约1分钱，月度成本在
2000-3000元，人工成
本单次约2元，AI成本优
势比较大，目标最大节
约30w另外，AI推荐的效
率开始显现，后续我们
继续汇报

老板，我觉得AI还是有
些问题的，很多我们的
老客户还是觉得要转人
工

人和AI的争端，就此展开

总结

选型的三个维度:能力、成本、风险

APB

任何一次选型决策,都要同时看这三个面 —— 缺一个都会翻车。



能力

够不够用

文本能力、多模态、上下文长度、工具调用



成本

花得起吗

单次成本、规模成本、隐性成本



风险

靠谱吗

稳定性、合规、供应商锁定、数据安全

这节课的模块二三讲「能力」,模块四讲「成本」,模块六讲「风险」—— 三维齐备。

模型微调成本-参考要素

APB

模型选择

基础模型大小

预训练语料库的范围与深度

微调数据集

数据量

数据处理

微调次数和迭代

训练周期

实验次数

计算资源

GPU、TPU使用数量和时长

存储和贷款费用


技术支持

专家支持

定制开发

大模型选型上的不可能三角

APB



文本能力的六个维度

APB

别笼统说「这个模型强」——拆成六个维度,才知道强在哪、够不够用。



推理能力

多步逻辑、数学、复杂判断



长文本

能吃多长的上下文,长了会不会失焦



指令遵循

让它干什么就干什么,不自作主张



工具调用

能不能准确地调 API、传对参数



中文能力

中文理解和表达是否地道



生成质量

文笔、结构、风格可控性

对 Agent 类产品,「指令遵循」和「工具调用」往往比「推理能力」更影响成败。

多模态生成:选型看什么

APB

生成类模型的评估维度,和理解类完全不同。



画面质量

出图好不好看、细节到不到位



指令还原度

有没有按描述画,细节对不对



中文理解

中文提示词能不能准确理解



文字渲染

图里的中文字能不能写对(常见弱项)



生成速度

一张图几秒还是几十秒



一致性

多次生成能否保持风格/角色一致

中文场景特别注意两点:中文提示词理解、图中中文字渲染 —— 这两项差异极大。

TTS 选型:六个评估维度

APB

语音的「像不像人」,决定了体验是加分还是出戏。



自然度

听起来像真人还是机器腔



音色选择

有多少音色可选、能不能定制



情感表达

能不能有语气起伏、情绪



流式延迟

第一个字多久出来(实时对话关键)



多语言方言

支持哪些语言、有没有方言



可控性

语速、停顿、多音字能否调整

实时对话场景,「流式延迟」比「音质完美」更重要——卡三秒再好听也没用。

ASR 选型:六个评估维度

APB

实验室准确率和真实环境准确率,常常差很远。



识别准确率

标准普通话下的基础准确率



方言口音

带口音、方言时还准不准



噪声鲁棒性

嘈杂环境下的表现



实时性

流式识别延迟、边说边出字



垂类词表

能否加入行业术语、商品名



多语言

支持哪些语言、能否混说

「垂类词表」是被低估的功能 —— 把你的商品名加进去,识别准确率能明显提升。

收益算法一:替代人工怎么折算

APB

最直观的一种 —— AI 处理一次,相当于省了人工多少钱。

单次收益 = 人工处理一次的成本 × AI 独立解决的概率

(没解决的会转人工,那部分不算收益)

人工成本

客服月薪 + 五险一金 ÷ 月处理量 → 单次人工成本

示例假设

一次人工咨询成本约 2 元

AI 解决率

第六节 PRD 定的目标:70%

单次收益

2 元 × 70% = 1.4 元

注意乘上「解决率」—— 这是很多人算 ROI 时最容易忽略的折扣项。

收益算法二:提升转化怎么折算

APB

适合导购、推荐类场景 —— AI 让用户多买了多少。

单次收益 = 客单价 × 毛利率 × 转化率提升幅度

(要用 A/B 实验测出真实的转化提升,不能拍脑袋)

客单价

假设 80 元

毛利率

假设 30%

转化提升

A/B 实验测得提升 2 个百分点

单次收益

$80 \times 30\% \times 2\% = 0.48$ 元

转化提升必须靠 A/B 实验拿到

- 计算你之前做的入职工作流的token成本
- 和人工进行ROI比较



- w7-2 【增长与商业化】大模型产品增长与商业策略



智在必得

Thanks for having you all the way

