

AI PRODUCT MANAGER

AI产品方案与PRD设计实战

第10课 | 核心结构版

BUSINESS · SOLUTION · MVP · CAPABILITY · EVALUATION · PRD

10

项目主线：把模糊AI想法变成可验收PRD



01 业务背景与产品目标

先回答：为什么做、为谁做、要达到什么结果

现状

- 1 运营编写内容
- 2 → 提交审核
- 3 → 审核人员查看
- 4 → 标记问题
- 5 → 退回修改
- 6 → 运营重新提交
- 7 → 再次审核
- 8 → 审核通过
- 9 → 内容发布

业务现状：人工审核遇到哪些问题

数量

内容从几十条增长到几百条，审核工作量线性上升。

一致性

同一句话，不同审核人员可能给出不同判断。

规则变化

行业、渠道、版本和活动阶段持续变化。

数据沉淀


聊天式反馈无法形成风险类型、依据和修改记录。

核心矛盾：生产提速后，瓶颈转移到审核

$50\text{条} \times 5\text{分钟} = 250\text{分钟} \rightarrow 300\text{条} \times 5\text{分钟} = 1500\text{分钟}$

- AI提高了内容生产效率，却没有同步提高审核效率。
- 真正的问题不是“模型能不能审”，而是审核链路能不能扩展。

需求澄清：把业务诉求转成产品问题



用户分析：谁会使用和管理智能审核

内容运营

想知道哪里有问题、为什么有问题、应该怎么改。

人工审核

想直接看到机器发现了什么、依据是什么、为何转人工。

规则运营

关心规则版本、更新影响和历史内容追溯。

业务负责人

关心效率是否提升，以及业务风险是否可控。

目标定义：产品效果要如何验证

目标方向	产品目标	后续验证
效率	减少人工从头检查每条内容的重复工作	单条审核耗时、积压量
质量	提前发现高频、明确和语义型风险	漏判、误判、风险覆盖
一致性	把规则、依据和输出结构标准化	人工一致性、解析成功率
安全	不确定与高风险内容能够转人工	人工接管率、失败放行数

02 AI介入判断与能力分工

业务问题明确后，判断AI是否介入，以及各能力如何分工

方案选择：智能审核有哪些实现路线

纯人工

理解上下文、可以担责，但工作量随内容量线性增长。

纯规则

稳定、便宜、可解释，但难以覆盖隐含语义和上下文。

纯大模型

语义理解强，但结果波动、依据可能过时、责任不清。

混合方案

规则 + 大模型 + RAG + 人工，能力互补但系统复杂度更高。

方案比较：四种路线分别如何取舍

方案	语义理解	稳定性	当前依据	人工量	复杂度
纯人工	强	受人员一致性影响	人工查询	高	低
纯规则	弱	高	结构化规则	中	中
纯大模型	强	相对较低	容易缺失	中	中
混合方案	强	可通过分工改善	RAG管理	聚焦高风险	高

为什么不能只接大模型

不稳定

相同输入可能给出不同等级和结论。

依据过时

模型不一定知道内部最新规则。

难以追溯

不知道当时使用哪版规则和Prompt。

成本浪费

格式、词表和阈值不需要大模型判断。

输出难接入

一段自然语言无法稳定驱动产品流程。

责任越界

模型不能独立承担高风险最终责任。

分工原则：先按任务性质选择技术方案

任务性质	典型任务	优先能力
确定、可枚举	禁用词、必要声明、格式、明确阈值	规则
依赖上下文	暗示、同义改写、组合语义、误导表达	大模型
依赖当前资料	渠道规则、版本条款、历史争议结论	RAG
高风险或不确定	依据冲突、信息不足、责任判断	人工

能力分工①：哪些任务交给规则

词与表达

禁用词、敏感词、高风险固定短语。

声明与格式

必要风险提示、字数、字段和格式。

明确阈值

可以清楚枚举的业务限制和数值条件。

能力分工②：哪些任务交给大模型

隐含承诺

没有直接使用禁词，但整体表达暗示保证结果。

上下文误导

单句正常，组合后可能让用户产生错误理解。

同义绕过

用改写、否定、反讽或案例包装绕开固定词。

能力分工③：RAG和人工分别做什么

RAG知识库

- 检索当前有效规则
- 提供规则解释和正反案例
- 保留业务、渠道和版本信息

人工复核

- 处理高风险与信息不足
- 解决规则和证据冲突
- 作出需要责任人确认的最终判断

方案落地：四类能力怎样组成审核流程



流程选择：第一版为什么使用Workflow

Workflow适合当前主链路

- 必要步骤每次都执行
- 每个节点可以单独测试
- 失败位置容易定位和追踪

Agent留给后续复杂任务

- 多渠道自主收集材料
- 动态追问和外部调查
- 受控生成完整调查报告

贯穿案例：同一条文案如何被分层审核

贯穿案例

这款产品是目前最值得购买的理财产品，预计年化收益可达20%，收益稳定，完全不用担心亏损。

整体风险等级：高风险 | 机器建议：不允许直接发布 | 下一步：转人工复核

规则

绝对化与高风险短语

RAG

收益保证与数据规范

大模型

收益误导与风险隐瞒

人工

驳回并记录复核原因

03 结果动作与人工复核

方案选定后，设计审核结果如何进入真实业务流程

结果合并：三类能力分别发现了什么

来源	发现内容	产品价值
规则	命中“最值得购买”“不用担心亏损”	稳定召回明确问题
RAG	返回绝对化、收益保证与数据来源条款	提供当前审核依据
大模型	识别收益数据不足、收益误导和风险隐瞒	补充语义风险

结果合并：为什么要去重、留证据、给建议



结果结构：一条风险结果包含哪些字段

风险片段：完全不用担心亏损
风险类型：收益保证与风险隐瞒
风险等级：高
识别来源：规则 + 大模型 + RAG
审核依据：金融营销内容审核规则V3，第18条
修改建议：删除保证性表达，补充必要风险提示
是否需要人工复核：是

整体结果：一篇内容会进入哪种状态

机器预审通过

未发现阻断风险，依据完整，且属于当前支持范围。

建议修改

只有低风险或提示性问题，用户可以确认或修改。

退回修改

存在明确且可以通过修改解决的中风险问题。

转人工复核

高风险、不确定、依据不足、规则冲突或系统异常。

动作映射： 风险等级如何决定下一步

审核情况	整体结果	下一步
未发现风险	机器预审通过	进入原有后续流程
只有低风险问题	建议修改	用户确认、修改或申请人工
明确中风险问题	退回修改	生成新版本后重新审核
高风险、不确定或依据冲突	待人工复核	进入人工审核工作台

用户流程：运营怎样完成修改闭环



人工接管：哪些情况必须触发复核

高风险

命中红线规则或高风险语义。

不确定

模型无法稳定作出判断。

信息不足

缺少产品事实或业务上下文。

依据冲突

规则、知识或版本之间存在冲突。

用户申诉

运营对机器结论发起复核。

系统失败

重试后规则、RAG或模型仍未完成。

复核工作台：人工需要看到和处理什么


人工需要看到

- 原始内容与内容版本
- 机器风险、依据和原始输出
- 转人工原因与历史处理记录

人工可以执行

- 复核通过或驳回修改
- 调整风险类型与等级
- 升级给规则或专业负责人

任务状态：审核流程如何记录进度



04 MVP范围与能力优先级

流程闭环后，决定第一版做到哪里、暂时不做什么

MVP定义：第一版要跑通哪条最小闭环

- 功能少不等于能够验证价值。
- 第一版必须同时验证能力、效率和安全接管。

真实提交 → 机器预审 → 查看结构化结果 → 修改或人工复核 → 记录最终结果

核心假设：MVP首先验证什么

发现更多有效风险

混合方案能识别纯规则难以覆盖的语义风险，同时不过度增加误报。

减少人工重复工作

机器提前定位问题、提供依据和建议，人工不再从头检查所有内容。


异常可安全接管

不确定、高风险和失败任务可以完整交给人工处理。

阶段区分：PoC、MVP和完整产品有何不同

阶段	核心问题	需要具备
能力PoC	技术方案在历史样本上是否基本可行？	样本、规则、模型与离线对比
产品MVP	进入真实流程后是否提高效率且安全？	真实提交、人工接管、结果记录
完整产品	如何支持规模化、多渠道和复杂组织？	多模态、权限、批量、发布与运营平台

范围判断：一个功能是否应该进入MVP



试点范围：第一版主动收窄哪些维度

范围维度	MVP选择	暂不扩展
内容类型	文本营销文案	图片、音频、视频
业务范围	一个业务线或高频场景	全部行业与组织
渠道	少量规则相对明确的渠道	全渠道统一覆盖
处理方式	预审、修改、复核和重审	自动发布和处罚

必备能力：最小闭环需要哪些产品能力

提交

文案和必要上下文

规则

确定性风险检查

RAG

当前规则依据

大模型

语义风险识别

结果

结构化展示与合并

分流

通过、修改或转人工

复核

人工最终处理

追溯

版本、日志和失败记录

延后能力：哪些需求暂不进入第一版

多模态审核

图片、视频和音频会显著扩大技术与标准范围。

自动改写发布

不能在未确认事实和责任的情况下直接覆盖原文。

完整规则后台

第一版可以由产品与研发预配置规则。

复杂审批权限

先用最小角色和人工分配验证主链路。

Agent自主调查

关键审核步骤不允许被自主跳过。

优先级：先保障闭环，再提升效率和规模

P0 | 没有就无法试点

提交、规则、语义审核、结构化结果、人工接管、重审、日志。

P1 | 提高使用效率

更好的任务筛选、批量查看、修改辅助和基础统计。

P2 | 规模化扩展

多渠道、多模态、完整规则平台、复杂权限和自动发布。

试点方式：第一版如何小范围安全上线

试点方式

- 先跑历史样本PoC
- 选择一个团队影子运行
- 人工仍保留最终控制权

成功标准

- 有效风险发现能力提升
- 人工平均耗时下降
- 高风险无默认放行，复核量可承受

05 大模型能力输入与输出

MVP范围确定后，把模型审核写成可实现的能力契约

能力契约：一项AI能力要写哪些部分

目标

为什么需要这项能力

对象

处理什么内容

输入

模型能够看到什么

任务

模型具体判断什么

输出

必须返回哪些字段

约束

哪些规则必须遵守

异常

不确定与失败怎么处理

边界

明确不负责什么

任务定义：大模型究竟应该判断什么

范围过大的写法

- 判断文案是否合法
- 默认模型掌握全部法律事实
- 责任和验收标准都不清楚

可实现的写法

- 基于给定规则和事实识别营销表达风险
- 标记原文位置并说明依据
- 输出后续处理建议和不确定原因

输入设计：模型需要获得哪些信息

完整内容

标题、正文、按钮文案与必要上下文。

业务上下文

产品类型、渠道、用户、活动和内容用途。
。

产品事实

功能、适用范围、数据、价格和官方表述。
。

审核依据

当前有效规则、解释、案例和版本信息。

输出约束

风险类型枚举、原文定位和JSON结构要求。
。

输入示例：怎样把业务上下文传给模型

待审内容：完整营销文案

业务上下文：金融产品 | 小红书 | 成年人 | 拉新活动

产品事实：历史收益数据、统计周期、风险说明

规则依据：当前有效规则V3 + 正反案例

输出要求：限定风险类型；必须定位原文；信息不足不得编造

输出示例：怎样让系统稳定解析结果

```
{
  "overall_result": "need_human_review",
  "overall_risk_level": "high",
  "risks": [{
    "text_span": "完全不用担心亏损",
    "risk_type": "收益保证与风险隐瞒",
    "reason": "暗示本金和收益不会发生损失",
    "evidence": "规则V3-18",
    "suggestion": "删除保证性表达并补充风险提示",
    "need_human_review": true
  }]
}
```

动作决策：模型结果如何转成业务动作

模型结果	系统继续检查	后续动作
未发现语义风险	规则是否命中、调用是否完整	进入整体结果合并
低风险	是否允许运营自行处理	建议修改
中风险	规则要求与业务场景	退回修改或人工
高风险/信息不足	高风险路由和缺失信息	转人工或补充信息
输出异常/调用失败	能否安全重试	重试后转人工

任务拆分：修改建议和自动改写有何不同

模型可以提供

- 应删除或弱化的表达
- 需要补充的限制条件
- 一条参考性示例表达

第一版不能自动做

- 直接覆盖运营原文
- 跳过重新审核
- 在缺少事实时自行补充内容

异常定义：不确定和失败结果如何处理

信息不足

指出缺少什么、为何影响判断，以及补充或转人工。

依据冲突

展示冲突依据，不让模型自行选择最终结论。

定位不稳定

允许返回段落级风险，并降低自动处理程度。

结构错误

缺字段、值越界或无法解析都视为机器失败。

调用失败

有限安全重试，仍失败则转人工并保留记录。

能力边界： 哪些责任不能交给大模型

模型不负责	原因
替代法务或规则负责人作最终结论	模型不承担最终业务与法律责任
判断未提供证据的产品事实是否真实	模型不能凭常识补齐内部事实
自动放行高风险或不确定内容	业务动作由系统规则与人工控制
自动覆盖原文、发布、删除或处罚	建议仍需用户确认并重新审核
在缺少依据时编造审核规则	必须允许返回信息不足

06 评测集来源与验收约定

能力契约写清后，约定用什么数据、如何判断能否上线

数据来源：首版评测集从哪里获得样本

历史记录

通过、驳回、修改前后版本和人工备注。

高风险案例

投诉、损失、红线和不能漏掉的典型问题。

争议案例

审核分歧、申诉、升级和规则冲突内容。

近期样本

最近业务、新产品、新渠道和新型规避表达。

边界样本

人工构造并用模型扩写的正反与临界变体。

标签治理：历史标签为什么不能直接使用

历史数据的价值

来自真实业务，能够反映常见表达、风险分布和人工流程。

历史数据的问题

人工标准不一、规则可能失效、备注不完整、旧错误可能被保留。

进入评测集前

历史样本抽样复核；高风险和争议样本逐条确认。

表格结构：评测集每一行要记录什么

字段组	典型字段	作用
样本输入	文案、业务场景、产品事实、渠道	还原模型实际可见信息
标准答案	风险类型、等级、位置、预期处理	明确什么算正确
样本元数据	来源、重要性、确认人、规则版本	保证可追溯
运行记录	模型输出、版本、评分和Bad Case	支持比较与回归

整理流程：如何从历史数据形成评测集



冷启动：没有历史数据怎样建立评测集

启动阶段

- 从规则文档整理风险类型
- 收集培训中的正反案例
- 业务人员编写典型违规样本

持续替换

- 模型生成表达变体后人工确认
- 两名业务人员独立判断分歧
- 影子运行后用真实案例替换构造数据

数据管理：开发、验收和回归样本为何分开

开发样本

产品、算法和研发可以反复查看，用于设计规则与Prompt。

验收样本

方案基本稳定后判断是否达到上线条件，避免针对题目调答案。

回归样本

重要错误、高风险和线上问题；规则、模型或Prompt变化后重跑。

验收约定：PRD必须提前写清哪些问题

约定项	需要明确
评测对象	单独模型、组合审核结果，还是完整产品闭环
样本来源	历史、近期、高风险、争议和构造样本分别从哪里来
风险范围	本次MVP必须覆盖什么，暂不验收什么
标准答案责任人	谁确认风险类型、等级和预期动作
上线门槛	高风险底线、识别要求、输出可用性和人工承载量
版本变化	规则、知识、模型、Prompt或结构变化后何时重新验收

07 产出完整AI产品PRD

把前六步的产品判断组装成可开发、可验收的PRD

PRD差异：AI产品需求多写了哪些内容

普通PRD通常关注

- 用户、场景与业务流程
- 页面、功能与状态
- 权限、数据和异常路径

AI产品PRD还必须关注

- AI介入依据和能力边界
- 输入、输出、版本与失败接管
- 评测集来源和上线门槛

文档结构：完整AI产品PRD包含哪十三章

01—04 业务	05—08 方案与范围	09—13 能力与保障
项目摘要	AI介入判断与备选方案	AI输入、输出与边界
业务背景与现状	能力分工	数据、规则与知识依赖
用户、场景与流程	审核结果与处理流程	评测集与验收条件
问题、目标与非目标	MVP与试点范围	12 人工复核与异常处理 13 风险与待确认项

首页摘要：怎样用一页说清整个项目

01

业务问题：内容量增加导致审核积压、标准不一和结果难沉淀

02

产品方案：规则 + RAG + 大模型 + 人工的分层机器预审

03

MVP范围：文本、单一业务试点、修改复核重审闭环

04

验收方式：能力效果、人工效率、安全底线和失败接管

组装顺序：前六步如何进入同一份PRD



运行依赖：数据、规则和知识库要说明什么

依赖	需要说明	典型风险
业务数据	内容、产品事实、渠道和历史记录	字段缺失、事实未结构化
规则	适用范围、版本、责任人和更新机制	标准冲突、版本不一致
知识库	来源、切分、检索和有效期	召回不足、过期依据
模型与Prompt	版本、配置、输出结构和回归要求	波动、格式错误、成本与延迟

决策清单：风险与待确认项如何写进PRD

待确认项	当前情况	影响
人工审核基线	需要从业务系统补充	效率目标与收益测算
高风险判断标准	需要规则负责人确认	自动处理范围
历史数据质量	尚未完成抽样检查	评测集可靠性
模型响应与复核承载	需要PoC和业务测算	体验与风险阈值

作业

练习一 | PRD首页

- 业务问题与目标用户
- 产品目标和混合审核方案
- MVP范围与验收方式

练习二 | AI能力

- 模型处理什么、能获得什么
- 必须输出什么、何时转人工
- 模型明确不负责什么