

大模型选型

Token 成本与 ROI

第 11 课

从“调用大模型”到一份可评审的产品决策

11

从PRD进入模型选型

PRD写清了分工，但“调用哪个模型”仍然没有答案

01

规则

敏感词、固定格式、确定性业务逻辑

02

大模型

复杂语义判断、风险原因与修改建议

03

人工

高风险、低置信度和异常结果复核

04

产品输出

风险等级、风险原因和处理建议

剩余问题

“复杂语义判断交给大模型”——到底交给哪一个？

为什么不能直接用最好的大模型

最好的大模型也比人工便宜，为什么不能用？

成本也是产品力的一个重要组成部分

模型选型的工作场景

同一个审核任务，三个候选模型没有脱离场景的唯一答案

候选模型	准确率	响应时间	单次成本
模型 A	98%	5 秒	0.30 元
模型 B	96%	1 秒	0.03 元
模型 C	91%	0.3 秒	0.005 元

先问 7 个业务问题

- 任务：具体审什么？
- 风险：错一次代价多大？
- 体验：用户能等多久？
- 规模：每天多少条？
- 接管：能否人工复核？
- 数据：能否发送外部？
- 预算：能承担多少？

判断原则

最强模型 ≠ 最适合的模型。先确定场景约束，再比较候选模型。

模型是能力的天花板，也是成本中心

选错模型会产生什么后果

API单价只是局部，最终问题会出现在效果、总成本、体验和风险上

01

能力不够

漏判和误判过多，大量结果回到人工，便宜模型反而不省钱。

02

能力过剩

只提升少量效果，却让响应时间和调用成本成倍增加。

03

体验不匹配

后台离线可等十分钟；发布前实时审核可能连十秒都不可接受。

04

风险不满足

数据、合规、稳定性和供应商切换能力不通过，效果再好也不能上线。

看整体

“模型便宜”不等于“系统省钱”，“模型强”也不等于“产品适合”。

模型选择不是一个技术问题

技术团队回答“怎么接”，产品经理定义“什么才算值得接”

技术团队

- **接入：**接口、并发与部署
- **测试：**评测集上的表现
- **工程：**稳定性与资源要求
- **故障：**限流、超时与恢复

产品经理

- **标准：**什么错误能接受？
- **体验：**用户最多等多久？
- **经济性：**单次和月度成本合理吗？
- **决策：**达到什么条件才上线？

真正产出

不是“选了模型B”，而是一份能进入评审、预算与研发实施的选型结论。

模型选型的三个比较维度

三个问题缺少任何一个，选型都可能失败

01

能力与性能

能否完成真实业务任务？

效果、召回、结构化输出、上下文、速度与特殊能力

02

完整成本

业务是否承担得起？

调用、重试、工具、人工、开发、维护与错误损失

03

长期风险

能否稳定合规地使用？

数据、合规、稳定性、部署方式与供应商切换

比较逻辑

先判断能不能用，再判断用起来是否划算、能否长期使用。



不可能三角

能力与性能

不要问模型“聪不聪明”，要问它在业务任务上是否达标

01

业务判断

风险类型、等级和上下文组合

02

高风险召回

漏判、误判和低置信度比例

03

结构化输出

JSON、字段、枚举与原文引用

04

上下文

长内容、中间信息和Token增长

05

响应速度

首字、完整、P95与高峰稳定性

06

特殊能力

多模态、工具调用、批量与私有化

指标来源

评测指标来自业务目标：审核看漏判，客服看解决率，报告看事实与完整性。

不要迷信榜单

成本不能只看公开单价

低价模型如果带来更多人工复核，整体成本可能更高

模型公开价格

输入 Token
+ 输出 Token



完成一次业务任务的总成本

- 流程：调用次数、重试与反思循环
- 服务：OCR、检索、存储和第三方接口
- 交付：开发、数据、测试、监控与维护
- 人工：复核、异常处理和返工
- 风险：失败与错误结果造成的损失

成本口径

比较的是“完成任务付出多少”，不是“一百万Token谁最便宜”。

输入token的大头是哪个部分？

风险与国内业务环境

部分项目的候选池会先被行业、采购、数据和部署条件缩小

01

数据风险

外部传输、留存、训练使用、个人信息与商业秘密

02

合规风险

地区、行业、审计留痕、版权、隐私与内容安全

03

稳定性风险

可用性、限流、超时、版本变化和效果漂移

04

供应商风险

涨价、停服、接口变化、迁移和厂商绑定

特殊部署硬门槛

国内备案与服务要求 · 数据不出域 · 内网/离线运行 · 国产软硬件适配
日志审计 · 权限隔离 · 私有化部署 · 真实中文业务数据测试

先排除

硬门槛应在建立候选名单前确认，而不是模型测完才发现无法采购或部署。

按目标建立模型候选池

具体名单用于缩小测试范围，不是长期有效的排行榜

选型目标	国外候选示例	国内候选示例	典型场景
优先质量	GPT-5 / Claude Sonnet	Qwen-Max / DeepSeek V4 Pro / Kimi K3 / GLM	复杂推理、多步骤任务
优先速度	GPT-4o mini / Llama-8B	Qwen-7B / Yi-Lightning / Doubao Lite	实时语音、高频客服
优先成本	—	DeepSeek V4 / Qwen-2.5-7B	离线分析、批量处理



模型选型不能直接加权打分

合规不通过，不能靠效果高分把总分补回来

错误做法：所有指标一起平均

效果 40

速度 20 + 成本 20

风险 20

硬风险可能被其他高分掩盖



正确顺序：门槛 → 比较

STEP 1

先淘汰任何硬门槛不通过的模型

STEP 2


只在通过者中比较稳定性、总成本、维护和供应商风险

决策顺序

先判断能不能用，再判断哪个更划算。

模型选型的完整实施流程

从业务任务开始，而不是从“最近哪个模型最火”开始



最终选型记录

业务任务·验收标准·候选与评测结果·成本测算·风险分析
主模型与备选模型·路由与人工复核·当前结论·重新评测条件

可复评

选型记录不是永久结论；模型、价格和业务量变化后都要重新评估。

先把“智能审核”拆成AI任务

产品包含多个AI任务时，应分别选型，不默认一个模型全包

AI任务	需要的能力	可观察输出
文本风险判断	语义理解、规则理解、分类判断	风险类型与等级
风险原因解释	内容生成、事实一致性	原因与原文证据
修改建议生成	指令遵循、文案生成	可执行的修改方案
图片文字审核	OCR或多模态理解	文字与图文风险
审核结果结构化	JSON输出、字段稳定性	可被后端消费的数据

任务定义 越能明确输入、输出和判断标准，模型测试越可比。

不同产品阶段的选型目标

同一个产品在验证、试点、规模化和成熟阶段，不应追求同一件事

01 · 验证

能力上限

先判断能不能做
暂不追求最低成本

02 · 试点

稳定可控

效果、体验、人工
和成本形成平衡

03 · 规模化

系统效率

路由、工程优化
控制单位任务成本

04 · 成熟

长期经济性

再评估私有化
开源与微调

阶段原则

验证失败先改任务和流程；成熟也不意味着一定私有化或微调。

验证阶段

核心原则

用最好的

目标

快速验证场景是否可解

试点阶段

核心原则

不改变流程的情况下，综合考虑成本、速度和业务场景，选择最合适的

目标

找到大部分场景的最优模型基座

规模化阶段 - 模型路由

不同难度、风险 and 价值的任务，进入不同处理层

规则处理

确定性规则 · 最快最便宜

轻量模型

简单分类 · 低风险初筛

主模型

复杂语义 · 综合判断

强模型 / 人工

极高风险

路由逻辑

先用低成本确定性能力处理；任务越复杂、风险越高，处理能力越强。

模型路由与失败降级

一个决定正常情况下交给谁；另一个决定原方案失败后怎么办

模型路由：正常分工

- **规则路由：**按行业、长度、模态和风险
- **分类路由：**先判断难度与后续模型
- **置信度路由：**不一致或低置信度升级
- **价值路由：**按任务价值配置资源

失败降级：异常兜底

- **模型超时：**切换备选模型
- **格式失败：**程序修复或有限重试
- **连续失败：**进入人工队列
- **外部停服：**保留规则与基础流程

产品要求

降级不仅是接口异常处理，还要明确用户看到什么、多久返回。

模型路由能省多少钱

把强模型留给真正复杂的5%任务

原方案

100% 强模型

平均 0.08元 / 任务



路由后	占比	单价
轻量模型	60%	0.005元
主模型	35%	0.03元
强模型	5%	0.08元

加权平均 = 0.0175元 / 任务

必须验证

路由本身也会出错：高风险任务是否被误分到低能力模型？

成熟阶段

私有化与微调都是选项，不是成熟产品的必经之路

01

是否值得微调

数据是否足够且稳定？
提升能否通过评测证明？
底座升级后如何维护？

02

是否值得私有化

是否存在数据硬门槛？
GPU、部署和运维多少钱？
团队是否具备维护能力？

03

何时重新选型

新版本或价格变化
业务量、模态和Bad Case变化
合规、稳定性或人工比例变化

切换流程

候选 → 回归评测 → 小流量灰度 → 观察真实结果 → 再全面切换。

AI PRODUCT MANAGER

多模态

多模态的场景

图片、文档、语音和视频对应不同输入、输出、评测和计费

能力类型	输入	输出	典型任务
多模态理解	图片 / 文档 / 视频	文字或结构化结果	看图、读表、页面解析
图片与视频生成	文字 / 图片	图片或视频	海报、商品图、营销视频
TTS语音合成	文字	音频	配音、语音客服
ASR语音识别	音频	文字	转写、字幕、质检

选型对象

多模态产品经常选择的是一组模型与处理流程，而不是一个“全能模型”。

区分识别、提取和理解

同一张营销海报，三个层次对应完全不同的能力



海报示例：“三天瘦十斤，无效退款”

OCR能读出文字；视觉理解还要判断免责声明、小字弱化和图文组合后的风险。

PRD写法

不要只写“使用多模态模型识别图片”，要明确到底完成哪一层任务。

图片与文档理解模型看什么

高清标准图测得好，不代表真实用户素材也能处理

01

文字识别

中文、小字、旋转、艺术字、模糊和表格数字

02

语义理解

人物、商品、图文关系、视觉暗示和趋势

03

结构空间

标题正文、栏列、跨页表格、免责声明关联

04

输入限制

张数、格式、分辨率、PDF页数和批量能力

05

时间成本

图片、分辨率、视觉Token、页数与调用次数

真实评测

必须包含截图、拍照、压缩图、小字、复杂背景与坏样本。

发票报销场景，需要用到多模态么？

生成、TTS与ASR的选型重点

不同模态不能共用一套评价指标

01

图片 / 视频生成

生成质量与指令遵循
主体和品牌一致性
局部编辑与参考图
平均生成次数和成本
版权、肖像与深度伪造

02

TTS 语音合成

自然度与发音准确性
数字、金额、术语和缩写
情绪与声音风格
实时首段延迟
声音克隆授权与防滥用

03

ASR 语音识别

口音、中英混合与术语
噪声、回声和多人说话
说话人区分与时间戳
实时与离线处理
音频存储、校对与隐私

隐藏成本

生成一次不满意会继续生成；真实任务成本要乘以平均尝试次数。

成本计算

一次请求里哪些内容消耗Token

用户输入只是模型真实上下文中的一小部分

输入组成	Token示例	是否容易忽略
System Prompt与角色说明	800	是
风险分类与审核规则	1,200	是
输出字段与格式要求	300	是
RAG法规内容	1,500	是
用户营销内容	400	否
Few-shot示例	600	是
输入合计	4,800	—

一次调用

4,800 输入Token

+ 600 输出Token

以实际调用日志为准

Token认知

不要用固定汉字比例长期估算；不同模型和模态的计费方式不同。

单次模型调用成本

输入与输出通常分别计价

$$\text{单次调用成本} = \text{输入成本} + \text{输出成本}$$

01

输入成本

$$4,800 \div 1,000,000 \times 2 \\ = 0.0096 \text{ 元}$$

02

输出成本

$$600 \div 1,000,000 \times 8 \\ = 0.0048 \text{ 元}$$

03

本次调用

$$0.0096 + 0.0048 \\ = 0.0144 \text{ 元}$$

教学假设

一次调用约1.44分钱，但这还不是一次业务任务的完整成本。

一次调用不等于一次业务任务

多节点调用要按发生概率折算平均成本

调用环节	单次成本	发生概率	平均成本
轻量分类模型	0.001元	100%	0.001元
主审核模型	0.0144元	70%	0.01008元
强模型复核	0.08元	5%	0.004元
格式修复调用	0.005元	3%	0.00015元
平均业务任务模型成本	—	—	0.01523元

任务成本

Σ

每个节点成本
× 触发概率

计算对象

以业务任务为单位，把所有可能发生的模型节点算进来。

重试与规模化成本

单次看似便宜，重试和业务量会把差异放大

01

考虑重试

理论任务成本 0.015元
8%请求重新调用

$$0.015 \times 1.08 \\ = 0.0162\text{元}$$

02

每天 5 万条

$$0.0162 \times 50,000 \\ = 810\text{元 / 天}$$

$$\times 30\text{天} \\ = 24,300\text{元 / 月}$$

03

每天 50 万条

$$0.0162 \times 500,000 \\ \times 30\text{天}$$

$$= 243,000\text{元 / 月}$$

规模效应

单次只差一分钱，规模化后也可能形成显著月度差异。

日志要记录：每个任务实际调用几次、哪个节点最贵、哪些调用来自失败与重试。

平均成本会掩盖任务分布

成本表应按照业务任务分类，而不是只按照模型名称分类

内容类型	典型输入	调用方式	单次成本
短标题	100字	轻量模型	0.002元
普通营销文案	800字	主模型	0.015元
长图文方案	5,000字	主模型 + RAG	0.08元
高风险金融文案	2,000字	主模型 + 强模型复核	0.15元
图片海报	1张图片	OCR + 视觉模型	0.20元

同时观察

平均值
中位数
P95 Token
最大值

P95价值

帮助决定输入限制、长文拆分、单独定价、预算与限流。

人工复核可能比Token更贵

优化方向要看成本占比，而不是盯着最容易计算的一项

月度模型成本

24,300 元

5万条 / 天
任务成本 0.0162元



月度人工复核成本

225,000 元

5万条 / 天 × 10%复核率
× 1.5元 / 次 × 30天

关键杠杆

复核率从10%降到5%，可能比压缩几百个Token更有价值。

AI产品的完整成本

项目能否持续运行，取决于四类成本共同作用

01

一次性建设成本

调研、产品、研发、集成、测试、数据、权限安全和培训

02

持续固定成本

维护、监控、知识更新、评测、运营、安全合规和基础设施

03

可变成本

Token、多模态、接口、存储带宽、人工复核、实施与重试

04

错误与风险成本

漏审、误拦、投诉、返工、处罚、品牌损失和客户流失

完整口径

模型贵一万元，但能显著降低重大风险时，这一万元可能值得。

计算成功完成一次任务的成本

请求数不是产品价值，成功完成的业务任务才是

如果按请求数计算

$$200 \div 10,000 \\ = 0.02\text{元}$$

但只有8,000次自动成功



按自动成功任务计算

$$200 \div 8,000 \\ = 0.025\text{元}$$

再加入人工复核，完整成本还会增加

监控升级

试点用真实样本测算；上线后按任务、节点、用户持续监控。

成本优化方法（一）

先优化处理方式和模型配置

01

规则与模型合理分工

关键词、计算、数据库和固定校验走确定性能力；复杂语义再调用大模型。

02

模型分层与路由

简单任务轻量模型，普通任务主模型，复杂任务强模型，高风险人工。

03

减少无效上下文

合并重复Prompt、保留有效Few-shot、按需读取资料，并验证缓存效果。

04

控制RAG召回

调整Top K、切片、去重和重排；只保留支持当前判断的片段。

边界

不能为了省Token，把真正需要语义理解的任务强行堆成复杂规则。

成本优化方法（二）

再控制状态、循环、时效和多模态调用

05

控制对话历史

近期对话 + 摘要 + 结构化状态；按当前任务读取必要记忆。

06

限制重试与循环

最大调用次数、输出长度、任务时长、预算上限和人工接管条件。

07

区分实时与异步

用户等待的任务追求延迟；批处理任务可换更慢更便宜的方案。

08

控制多模态调用

图片先压缩和OCR，视频拆音轨与关键帧，只在必要时升级视觉模型。

产品约束

成本控制要写进产品：次数、时长、输入大小、预算和退出条件。

所有降本动作都要重新评测

成本下降不等于优化成功

指标	优化前	优化后	判断
高风险召回率	96%	95.5%	通过
结构化输出成功率	98%	98%	通过
P95响应时间	1.2秒	0.8秒	通过
单次任务成本	0.015元	0.009元	改善
人工复核率	10%	11%	需评估
自动完成率	70%	72%	改善

- 01

提出方案

明确改了什么
- 02

回归评测

第9课评测集
- 03

小流量测试

观察真实行为
- 04

正式采用

效果和总成本都通过

上线条件

关键业务指标跌破验收线，即使成本下降也不能上线。

AI PRODUCT MANAGER

收益

AI产品的收益从哪里来

收益必须可验证，并说明如果没有AI是否仍会发生

01

节省人工成本

原人工处理量 × 单次人工成本 – AI上线后剩余人工成本

02

提升工作效率

原处理时长 – AI处理后时长；只有真正释放或复用的时间才算价值

03

增加收入

业务量 × 转化率提升 × 单笔毛利；最好通过A/B或前后对照验证

04

降低风险损失

风险发生概率 × 单次损失；明确数据来源与不确定性

避免虚高

不要把效率提升与人工节省、收入增长与全部GMV重复计算。

智能审核项目的回本测算

AI持续成本降到8.8万元/月，每月净节省11.2万元

项目	原人工方案	AI方案
月审核量	10万条	10万条
一次性建设成本	—	30万元
模型、工具和基础设施	—	0.8万元/月
人工审核成本	20万元/月	6万元/月
运营、维护和评测	—	2万元/月
每月持续成本	20万元	8.8万元

回本周期

$30 \div 11.2$
 ≈ 2.68 个月

盈亏平衡任务量
 ≈ 26.8 万条

同一结论 回本周期按时间看；盈亏平衡任务量按业务量看。

六个月投入产出

一次性投入必须和观察周期一起计算

01

没有AI

20万元 × 6个月

= 120万元

02

AI方案

30万元建设
+ 8.8万元 × 6

= 82.8万元

03

六个月结果

节省 37.2万元

ROI ≈ 44.9%

谨慎解释

还要验证审核量、自动完成率、真实人力释放、风险与季节波动。

教学示例，不代表所有AI审核项目都能在三个月回本。